

Resumen

La Influenza Aviar Altamente Patógena (IAAP) constituye una amenaza creciente para la sanidad animal por su elevada capacidad de dispersión, impacto económico y potencial zoonótico. La aparición de casos en mamíferos ha incrementado el interés por comprender la transmisión interespecie y mejorar la vigilancia epidemiológica.

~~Este Trabajo Fin de Grado~~ aborda dicha problemática desde la Ingeniería Informática, aplicando minería de datos, análisis geoespacial y aprendizaje automático sobre datos reales de brotes de IAAP proporcionados por investigadores del INIA-CSIC. Comprende la integración de fuentes heterogéneas: registros de brotes, cartografía de áreas de interés para la biodiversidad, humedales protegidos e índices de riqueza de especies, mediante procesos ETL, así como el estudio de patrones espaciales, temporales y taxonómicos en su distribución.

A partir de los datos procesados se realiza un análisis del *dataset* para identificar relaciones entre los brotes en aves y mamíferos y la influencia de variables geográficas y ecológicas, como la distancia a humedales protegidos o la pertenencia a áreas de interés para la biodiversidad. Posteriormente se implementan modelos de clasificación (Random Forest y Regresión Logística) para evaluar la capacidad de estas variables, junto con la información taxonómica, para predecir el grupo taxonómico del animal afectado, distinguiendo aves y mamíferos.

Al comparar el funcionamiento del modelo de aprendizaje automático Random Forest con un modelo de referencia, la Regresión Logística, se observa que el primero ofrece un mejor desempeño con las variables geográficas y ecológicas integradas, alcanzando una precisión global del 83 % frente al rendimiento más limitado del segundo. Al aplicar el modelo Random Forest sobre el subconjunto de registros de España, la precisión asciende al 93 %, lo que viene a confirmar la idoneidad de su elección. Estos resultados permiten valorar la utilidad de la minería de datos y el aprendizaje automático en este ámbito, identificando patrones y limitaciones del conjunto de datos. Como líneas futuras, se plantea incorporar variables climáticas y de movilidad aviar, y reorientar el problema hacia la estimación directa de indicadores de riesgo de transmisión interespecie.

Palabras clave: Influenza Aviar Altamente Patógena (IAAP), Minería de Datos, Machine Learning, Análisis Geoespacial, Vigilancia Epidemiológica, Integración de Datos, Random Forest, Regresión Logística, Predicción de Riesgo, CRISP-DM.

Abstract

Highly Pathogenic Avian Influenza (HPAI) constitutes a growing threat to animal health due to its high dispersal capacity, economic impact, and zoonotic potential. The emergence of cases in mammals has heightened interest in understanding interspecies transmission and improving epidemiological surveillance.

~~##### This Document #####~~ This addresses this problem from a Computer Science Engineering perspective, applying data mining, geospatial analysis, and machine learning to real-world data from HPAI outbreaks provided by researchers at INIA-CSIC. It comprises the integration of heterogeneous sources (such as outbreak records, mapping of areas of interest for biodiversity, protected wetlands, and species richness indices) through ETL processes, as well as the study of spatial, temporal, and taxonomic patterns in their distribution.

Based on the processed data, a dataset analysis is conducted to identify relationships between outbreaks in birds and mammals, and the influence of geographical and ecological variables, such as distance to protected wetlands or inclusion within areas of interest for biodiversity. Subsequently, classification models (Random Forest and Logistic Regression) are implemented to evaluate the capacity of these variables, along with taxonomic information, to predict the taxonomic group of the affected animal, distinguishing between birds and mammals.

When comparing the performance of the Random Forest machine learning model against a baseline model, Logistic Regression, it is observed that the former delivers better performance with the integrated geographical and ecological variables, reaching an overall accuracy of 83 % compared to the more limited performance of the latter. When applying the Random Forest model to the subset of records from Spain, the accuracy rises to 93 %, confirming the suitability of its selection.

These results highlight the utility of data mining and machine learning in this field, identifying patterns and limitations within the dataset. As future lines of work, it is proposed to incorporate climate and avian mobility variables, and to reorient the problem toward the direct estimation of risk indicators for interspecies transmission.

Keywords: Highly Pathogenic Avian Influenza (HPAI), Data Mining, Machine Learning, Geospatial Analysis, Epidemiological Surveillance, Data Integration, Random Forest, Logistic Regression, Risk Prediction, CRISP-DM.

Índice General

1. Introducción.	1
1.1. Influenza Aviar Altamente Patógena.	1
1.1.1. Factores epidemiológicos relevantes.	2
1.1.2. Factores de dispersión.	3
1.2. Relevancia del análisis predictivo.	3
1.3. Motivación del TFG.	4
2. Objetivos.	6
3. Estado del arte.	7
3.1. Predicción de proliferación de enfermedades.	7
3.2. Modelos matemáticos. Técnicas de análisis exploratorio.	8
3.3. Aplicaciones de <i>machine learning</i> en epidemiología.	9
3.4. Plataformas actuales y infraestructuras de datos.	10
3.5. Desafíos actuales y limitaciones.	11
3.6. Fuentes de consulta no citadas.	12
4. Metodología.	13
4.1. Herramientas y entorno de implementación.	16
4.1.1. Código fuente y recursos complementarios.	17
4.2. Análisis inicial y comprensión de la información.	17
4.2.1. Preanálisis de las fuentes de datos.	18
4.2.2. Verificación de calidad e integridad de los datos.	19
4.2.3. Rectificación de fuentes.	21
4.3. Marco teórico del ETL.	23

4.4.	Preparación de datos.	24
4.5.	Análisis del <i>dataset</i>	29
4.6.	Introducción a la fase de <i>Machine Learning</i>	31
4.6.1.	Definición ampliada de conceptos utilizados.	32
4.6.2.	Modelo principal: <i>Random Forest</i>	37
4.6.3.	Modelo de contraste: Regresión Logística.	38
4.6.4.	Aplicación del modelo <i>Random Forest</i> sobre el contexto español. . . .	38
5.	Resultados.	40
5.1.	Minería de datos	40
5.1.1.	Orden Taxonómico	40
5.1.2.	Orden Huéspedes	42
5.1.3.	Evolución temporal 2005-2026.	43
5.1.4.	Densidad de brotes (Acumulada).	45
5.1.5.	Brotes según zonas geográficas.	48
5.1.6.	Valores de distancia a humedales.	49
5.1.7.	Distribución de brotes - Dentro de áreas protegidas vs fuera.	51
5.1.8.	Relación de brotes en aves vs mamíferos.	52
5.2.	<i>Machine Learning</i>	56
5.2.1.	Preprocesamiento para <i>Machine Learning</i>	56
5.2.2.	Modelo principal: <i>Random Forest</i> (RF).	57
5.2.3.	Modelo de contraste: Regresión Logística (RL).	60
5.2.4.	Comparativa de modelos.	62
5.2.5.	Aplicación sobre España.	63
5.3.	Síntesis de resultados por objetivos.	68
6.	Conclusiones y líneas futuras.	70
6.1.	Evaluación del objetivo general.	70
6.2.	Evaluación de los objetivos específicos.	70

6.2.1.	Integración y preparación del <i>dataset</i> analítico.	70
6.2.2.	Identificación de patrones taxonómicos, espaciales y temporales.	71
6.2.3.	Identificación y caracterización de la relación entre brotes en aves y mamíferos.	71
6.2.4.	Evaluación de la capacidad predictiva de las variables geográficas y ecológicas.	71
6.2.5.	Identificación y documentación de las limitaciones de los datos y modelos.	72
6.2.6.	Evaluación del rendimiento del modelo global en el contexto español. .	72
6.3.	Líneas futuras.	72
Referencias Bibliográficas		74
Anexo A		78
Anexo B		79
B.1.	Código ejecutado sobre las fuentes.	79
B.2.	Errores obtenidos en las fuentes.	80
B.3.	Datos obtenidos en las fuentes.	81
B.3.1.	Fuentes: brotes1.xlsx	81
B.3.2.	Fuentes: RiquezaEspecies.dbf	82
B.3.3.	Fuentes: features_centroid_publishedPoint.dbf	82
B.3.4.	Fuentes: sites.dbf	83
Anexo C		
C.1.	Fichero 1	
C.2.	Fichero 2	
C.3.	Fichero 3	
C.4.	Variables del <i>dataset</i> enriquecido	
Anexo D		

Lista de Figuras

Figura 1.	Fases del proceso metodológico: desde el preprocesado ETL hasta la evaluación y discusión de los modelos de aprendizaje automático. Fuente: Elaboración propia .	13
Figura 2.	Proceso de Integración. Fuente: Elaboración propia.	28
Figura 3.	Distribución de brotes por orden taxonómico. Fuente: Elaboración propia. . .	41
Figura 4.	Distribución de brotes por tipo de huésped. Fuente: Elaboración propia. . . .	43
Figura 5.	Evolución temporal de brotes de gripe aviar 2005-2026. Fuente: Elaboración propia.	44
Figura 6.	Densidad geográfica de brotes de gripe aviar (2005-2026). Fuente: Elaboración propia.	45
Figura 7.	Densidad geográfica de brotes de gripe aviar entre (a) 2004 y 2007 y entre (b) 2008 y 2011. Fuente: Elaboración Propia	46
Figura 8.	Densidad geográfica de brotes de gripe aviar entre (a) 2012 y 2015 y entre (b) 2016 y 2019. Fuente: Elaboración Propia.	46
Figura 9.	Densidad geográfica de brotes de gripe aviar entre (a) 2020 y 2023 y entre (b) 2024 y 2026. Fuente: Elaboración Propia	47
Figura 10.	Distribución de brotes por región geográfica. Fuente: Elaboración propia. . .	48
Figura 11.	Distancia al humedal Ramsar más cercano por orden taxonómico. Fuente: Elaboración propia.	49
Figura 12.	Distancia al humedal Ramsar más cercano por orden taxonómico (intervalo 0–1000 km). Fuente: Elaboración propia.	50
Figura 13.	Distribución de brotes dentro y fuera de áreas protegidas IBA/KBA por orden taxonómico. Fuente: Elaboración propia.	51
Figura 14.	Comparación de hotspots: aves (azul) vs mamíferos (rojo). Fuente: Elaboración propia.	53
Figura 15.	Matriz de confusión del modelo Random Forest global. Fuente: Elaboración propia.	59
Figura 16.	Importancia de variables en Random Forest. Fuente: Elaboración propia. . . .	60

Figura 17.	Matriz de confusión Regresión Logística global. Fuente: Elaboración propia.	
		62
Figura 18.	Gráfico comparativa F1-score por clase RF vs LR. Fuente: Elaboración propia.	62
Figura 19.	Matriz de confusión Random Forest aplicado sobre España. Fuente: Elaboración propia.	
		67
Figura 20.	Gráfico comparativa F1-score global vs España. Fuente: Elaboración propia.	67

Lista de Tablas

Tabla 1.	Verificación de calidad e integridad de los datos. Fuente: Elaboración propia. .	21
Tabla 2.	Rango de coordenadas del fichero 4	26
Tabla 3.	Comparación de cobertura entre ambos ficheros	27
Tabla 4.	Variables del <i>dataset</i> enriquecido	29
Tabla 5.	Informe de clasificación por clase ML	58
Tabla 6.	Resumen de métricas globales del modelo ML	58
Tabla 7.	Informe de clasificación por clase RL	61
Tabla 8.	Resumen de métricas globales del modelo RL	61
Tabla 9.	Informe de clasificación por clase ML-ES	66
Tabla 10.	Resumen de métricas globales del modelo ML-ES	66
Tabla 11.	Resumen de objetivos e indicadores clave	68
Tabla 12.	Fuentes: brotes1.xlsx. Tipología de campos	81
Tabla 13.	Fuentes: brotes1.xlsx. Registros erróneos o vacíos	82
Tabla 14.	Descripción de campos de RiquezaEspecies.dbf	82
Tabla 15.	Descripción de campos de features_centroid_publishedPoint.dbf	82
Tabla 16.	Registros erróneos o vacíos en features_centroid_publishedPoint.dbf	83
Tabla 17.	Descripción de campos de sites.dbf	83
Tabla 18.	Registros erróneos o vacíos en sites.dbf	84
Tabla 19.	Variables contenidas en esta fuente de datos de brotes	
Tabla 20.	Distribución de registros por orden taxonómico en el dataset original	
Tabla 21.	Variables contenidas en esta fuente de datos (IBAs y KBAs)	
Tabla 22.	Valores únicos de las variables categóricas IBA/KBA	
Tabla 23.	Variables contenidas en esta fuente de datos (Humedales Ramsar)	
Tabla 24.	Variables del dataset enriquecido. Descripción detallada	

Glosario

Análisis exploratorio de datos: Proceso inicial en minería de datos que consiste en examinar un conjunto de datos para comprender su estructura, identificar patrones y detectar posibles anomalías. Incluye técnicas como visualización gráfica, análisis de correlaciones y detección de valores atípicos. Es una fase clave antes de aplicar modelos predictivos.

ARIMA (Modelos de series temporales): Modelo estadístico utilizado para analizar datos que evolucionan con el tiempo. Permite identificar patrones como estacionalidad, tendencias o ciclos, y generar predicciones basadas en valores pasados. En epidemiología se usa para anticipar brotes y estudiar su comportamiento anual, especialmente ante variaciones estacionales.

AUC-ROC: Métrica de evaluación utilizada en clasificación binaria que mide la capacidad discriminativa de un modelo mediante el área bajo la curva ROC (Receiver Operating Characteristic), representando el equilibrio entre verdaderos positivos y falsos positivos.

Balanceo de clases: Conjunto de técnicas utilizadas para corregir desequilibrios en la distribución de categorías dentro de un *dataset*, evitando que los modelos predictivos favorezcan excesivamente las clases mayoritarias.

BallTree con métrica haversine: Estructura de datos utilizada para la búsqueda eficiente de vecinos más cercanos en espacios métricos. Cuando se combina con la métrica haversine, permite calcular distancias sobre la superficie terrestre considerando su curvatura, lo que la hace especialmente útil en problemas geoespaciales con coordenadas de latitud y longitud.

Clustering (agrupamiento): Técnica de aprendizaje no supervisado que permite agrupar datos en función de su similitud. Se utiliza para identificar patrones ocultos dentro de un conjunto de datos. En epidemiología, ayuda a detectar agrupaciones de brotes con características comunes.

Correlación: Medida estadística que expresa el grado de relación entre dos variables. Una correlación alta indica que ambas variables evolucionan de forma similar, aunque no implica una relación causal directa. Es una herramienta habitual en el análisis exploratorio de datos.

CRISP-DM (Cross-Industry Standard Process for Data Mining): Metodología estándar ampliamente utilizada en proyectos de minería de datos que estructura el proceso en seis fases: comprensión del negocio, comprensión de los datos, preparación de los datos, modelado, evaluación y despliegue. Su objetivo es proporcionar un marco iterativo y no lineal que guía el desarrollo de proyectos de análisis de datos, asegurando la coherencia entre los objetivos del negocio y las técnicas de modelado aplicadas.

CSIC (Consejo Superior de Investigaciones Científicas): Organismo público de investigación en España que desarrolla actividades científicas en diversas áreas. En el ámbito de la epidemiología

veterinaria, contribuye con estudios y datos relevantes sobre enfermedades como la influenza aviar.

Dataframe: Estructura de datos bidimensional utilizada en lenguajes de programación como Python (especialmente en la librería *pandas*). Permite organizar información en filas y columnas, facilitando su manipulación, análisis y visualización.

DBF (.dbf): Formato de archivo de base de datos asociado a los shapefiles que almacena la información tabular o atributos descriptivos de las entidades geoespaciales. Mientras el archivo .shp contiene la geometría, el .dbf contiene los datos alfanuméricos vinculados a cada entidad espacial, como nombres, categorías o valores numéricos, permitiendo su análisis conjunto en sistemas de información geográfica (SIG).

EPSG:4326 (WGS84) : Sistema de referencia geodésico global basado en el datum World Geodetic System 1984. Expresa posiciones mediante coordenadas geográficas de latitud y longitud en grados decimales. Es uno de los estándares más utilizados en cartografía digital, sistemas de navegación (como GPS), aplicaciones SIG y también en mapas topográficos cuando se representan en coordenadas geográficas. Su uso facilita la interoperabilidad entre diferentes fuentes de datos espaciales y servicios de mapas.

ETL (Extract, Transform, Load): Proceso fundamental en ingeniería de datos que consiste en la extracción de datos desde múltiples fuentes, su transformación mediante limpieza, normalización y estructuración, y su posterior carga en un sistema destino, como un data warehouse. Es una etapa clave para garantizar la calidad, consistencia e integración de los datos antes de su análisis o modelado.

F1-score: Métrica de evaluación que combina precisión (precision) y exhaustividad (recall) mediante su media armónica, proporcionando una medida equilibrada del rendimiento del modelo especialmente útil en *datasets* desbalanceados.

FAO (Organización de las Naciones Unidas para la Alimentación y la Agricultura): Agencia internacional dedicada a mejorar la seguridad alimentaria y la sanidad animal. Coordina programas de vigilancia, recopila datos epidemiológicos y promueve la cooperación entre países para la detección temprana de brotes.

FAO EMPRES-i+: Sistema global de información epidemiológica desarrollado por la FAO. Reúne reportes oficiales de enfermedades animales, integra análisis automatizados de riesgo y permite visualizar brotes en tiempo real para ofrecer una base de datos homogénea a investigadores y autoridades.

Feature engineering: Proceso de creación, transformación y selección de variables con el objetivo de mejorar el rendimiento de los modelos de aprendizaje automático. Incluye tareas como

normalización, codificación de variables categóricas o generación de atributos derivados.

GISAID: Plataforma internacional que recopila y comparte secuencias genéticas de virus (influenza y coronavirus) en tiempo casi real. Facilita el análisis de mutaciones, la identificación de linajes emergentes y el seguimiento de la evolución viral a nivel global.

GitHub: Plataforma de desarrollo colaborativo basada en la nube, propiedad de Microsoft, que permite almacenar, gestionar y compartir código utilizando el sistema de control de versiones Git. Facilita el seguimiento de cambios, la colaboración entre equipos y la gestión eficiente de versiones de software.

HealthMap: Plataforma digital que recopila información sobre brotes a partir de fuentes oficiales y no oficiales (noticias, redes sociales). Utiliza algoritmos para detectar señales tempranas y generar mapas interactivos de riesgo que complementan los sistemas de vigilancia tradicionales.

Hemaglutinina (H): Proteína de superficie del virus de la influenza que facilita la unión y entrada del virus en las células del huésped. Su variabilidad determina los distintos subtipos virales y es clave en su capacidad infectiva.

Influenza Aviar Altamente Patógena (IAAP): Forma grave del virus (subtipos como H5 y H7) con mortalidades superiores al 90 % en aves de corral. Posee un alto potencial zoonótico (puede infectar a humanos) y genera graves impactos económicos, siendo de declaración obligatoria internacional.

Influenza Aviar de Baja Patogenicidad (IABP): Variante menos agresiva que produce síntomas leves, limitados generalmente al tracto respiratorio o digestivo. Requiere vigilancia constante porque puede evolucionar hacia formas altamente patógenas en poblaciones densas de aves.

INIA-CSIC: El Instituto Nacional de Investigación y Tecnología Agraria y Alimentaria es un Centro Nacional integrado en el Consejo Superior de Investigaciones Científicas (CSIC) y es la institución de referencia en España para la investigación, desarrollo e innovación (I+D+i) en los sectores agropecuario, alimentario y forestal.

KDE (Kernel Density Estimation): Técnica estadística no paramétrica utilizada para estimar densidades de probabilidad a partir de distribuciones discretas de datos. En análisis geoespacial permite transformar conjuntos de puntos en superficies continuas de densidad. El procedimiento consiste en situar una función kernel sobre cada punto observado y combinar posteriormente todas las contribuciones individuales para obtener una estimación continua de densidad. El resultado depende del ancho de banda utilizado, parámetro que controla el grado de suavizado de la distribución final.

Machine Learning (Aprendizaje Automático): Conjunto de técnicas que permiten a los algoritmos identificar patrones y realizar predicciones en grandes volúmenes de datos sin reglas explícitas.

Se utiliza para clasificar zonas de riesgo, analizar secuencias genéticas y detectar relaciones complejas en epidemiología.

Metapoblación (Modelos de metapoblación): Enfoque que representa sistemas formados por subpoblaciones conectadas mediante movimientos o migraciones. Permite estudiar cómo los brotes se desplazan entre humedales o rutas migratorias, identificando zonas clave de transmisión.

Modelos predictivos: Herramientas matemáticas o computacionales que permiten estimar la probabilidad de eventos futuros a partir de datos históricos. En epidemiología, se emplean para anticipar brotes y evaluar posibles escenarios de propagación.

Modelos SIR (Susceptible–Infectado–Recuperado): Modelos matemáticos que dividen una población en tres grupos para estudiar la dinámica de transmisión de enfermedades. Permiten estimar tasas de contagio y duración de brotes incorporando factores como densidad y movilidad.

Neuraminidasa (N): Proteína del virus de la influenza que facilita la liberación de nuevas partículas virales desde las células infectadas. Junto con la hemaglutinina, se utiliza para clasificar los subtipos del virus (ej. H5N1).

OMSA (antiguamente conocida como OIE) / WOAHA (Organización Mundial de Sanidad Animal): Organismo internacional que coordina la vigilancia y notificación de enfermedades animales. Establece normas sanitarias y obliga a los Estados miembros a reportar brotes de enfermedades críticas como la IAAP.

OIE-WAHIS AH:. Su base de datos es fundamental para estudios epidemiológicos globales, análisis de riesgo y la elaboración de modelos predictivos basados en información oficial.

Overfitting: Fenómeno de sobreajuste que ocurre cuando un modelo aprende excesivamente los patrones específicos y el ruido de los datos de entrenamiento, reduciendo su capacidad para generalizar correctamente sobre datos nuevos no utilizados durante el entrenamiento.

Potencial zoonótico: El potencial zoonótico es la capacidad o probabilidad que tiene un microorganismo (como un virus, bacteria o parásito) que vive naturalmente en los animales de saltar a los seres humanos y causar una infección. Este concepto no garantiza que la enfermedad se propague masivamente, sino que mide el riesgo inicial de contagio desde el animal hacia los humanos. Factores como la destrucción de hábitats naturales y el contacto cercano con animales salvajes aumentan las oportunidades de que este "salto" ocurra.

Preprocesado de dato: Conjunto de técnicas aplicadas a los datos antes de su análisis (limpieza, transformación y normalización). Su objetivo es mejorar la calidad del conjunto de datos y hacerlo adecuado para modelos analíticos.

ProMED: Sistema de vigilancia global basado en reportes de expertos y observadores locales. Publica alertas tempranas sobre brotes infecciosos y zoonosis, detectando a menudo eventos emergentes antes que los canales oficiales.

Ramsar Sites Information Service (RSIS): El Servicio de Información sobre Sitios Ramsar (RSIS o SISR) es la base de datos oficial y portal en línea de la Convención de Ramsar que proporciona información detallada sobre los humedales de importancia internacional (Sitios Ramsar).

Random Forest: Algoritmo de aprendizaje automático supervisado basado en la combinación de múltiples árboles de decisión entrenados sobre subconjuntos aleatorios de datos y variables. Su objetivo es mejorar la capacidad de generalización del modelo y reducir el riesgo de sobreajuste respecto a un árbol individual.

Raw Dataset: Conjunto de datos inicial obtenido tras la lectura e integración de las fuentes de información originales, previo a la aplicación de procesos de limpieza, transformación y validación. En el presente trabajo, el término *dataset* utilizado de forma aislada hará referencia a un conjunto de datos sobre el que ya se han aplicado las operaciones correspondientes al proceso ETL.

Redes Neuronales LSTM (Long Short Term Memory): Tipo de red neuronal diseñada para trabajar con datos secuenciales. Pueden aprender dependencias a largo plazo, lo que las hace superiores a los modelos estadísticos tradicionales para predecir brotes basados en patrones históricos complejos.

Regresión logística: Modelo estadístico supervisado utilizado en problemas de clasificación que estima la probabilidad de pertenencia de una observación a una determinada clase mediante una función logística. Se emplea habitualmente como modelo base por su simplicidad e interpretabilidad.

SEMMA (Sample, Explore, Modify, Model, Assess): Metodología desarrollada por *SAS Institute* para estructurar procesos de minería de datos orientados principalmente al modelado predictivo y se centra principalmente en las tareas técnicas de modelado.

Series temporales: Conjunto de datos organizados cronológicamente. Permiten analizar la evolución de una variable a lo largo de un periodo determinado, identificando tendencias, estacionalidad y cambios de comportamiento.

Sistemas de Información Geográfica (SIG): Herramientas que analizan datos geoespaciales mediante mapas digitales. Se utilizan para localizar "puntos calientes" de brotes y relacionarlos con factores ambientales como rutas migratorias de aves.

SIR y SEIR: Modelos matemáticos compartimentales basados en ecuaciones diferenciales, utilizados en epidemiología para simular la dinámica de propagación de enfermedades infecciosas mediante

la división de la población en estados discretos (Susceptible, Infectado, Recuperado, etc.).

Sitio Ramsar: Es un humedal de importancia internacional designado por un país bajo la Convención de Ramsar, reconocido por sus valores ecológicos, botánicos, zoológicos, limnológicos o hidrológicos únicos, y comprometido a ser conservado para las generaciones futuras.

Shapefile (.shp): Formato de archivo geoespacial ampliamente utilizado para almacenar información vectorial, como puntos, líneas o polígonos, junto con sus atributos asociados. Es un estándar en sistemas de información geográfica (SIG) y suele estar compuesto por varios archivos complementarios (.shp, .shx, .dbf, entre otros) que en conjunto representan la geometría y la información descriptiva de las entidades espaciales.

SMOTE (Synthetic Minority Over-sampling Technique): Técnica de balanceo de clases utilizada en problemas de clasificación con *datasets* desbalanceados. Consiste en generar nuevas muestras sintéticas de la clase minoritaria mediante interpolación entre ejemplos existentes, en lugar de duplicarlos, con el objetivo de mejorar el rendimiento de los modelos de machine learning y reducir el sesgo hacia la clase mayoritaria.

Spatial Join (sjoin): Operación de análisis geoespacial que permite unir dos conjuntos de datos espaciales en función de su relación geométrica, como intersección, contención o proximidad. Es una técnica clave para integrar información procedente de diferentes capas geográficas, permitiendo enriquecer *datasets* mediante relaciones espaciales entre entidades.

Validación cruzada: Técnica de evaluación de modelos predictivos que consiste en dividir el *dataset* en múltiples subconjuntos para entrenar y validar el modelo de forma iterativa, permitiendo estimar de manera más robusta su capacidad de generalización.

Vigilancia epidemiológica: Proceso continuo y sistemático de recogida, análisis e interpretación de datos sanitarios. Su objetivo es detectar brotes de forma precoz, monitorizar su evolución y apoyar la toma de decisiones en salud pública.

Zenodo: Repositorio de acceso abierto de propósito general, operado por el CERN (Organización Europea para la Investigación Nuclear) bajo el programa OpenAIRE (Infraestructura europea para promover y facilitar el acceso abierto a los resultados de la investigación en Europa), diseñado para que los investigadores depositen artículos, conjuntos de datos, software y otros artefactos digitales.

Zoonosis: Enfermedad que puede transmitirse de forma natural de animales a humanos. La influenza aviar es un ejemplo crítico cuando el virus se adapta a nuestra especie, representando un riesgo de pandemia.

1. Introducción.

La influenza aviar altamente patógena (IAAP) constituye uno de los principales problemas sanitarios dentro de la producción avícola moderna debido a su capacidad de dispersión, elevada mortalidad y potencial zoonótico (capacidad de un agente patógeno animal para infectar a los seres humanos, pudiendo provocar una enfermedad.). Aunque el riesgo para la población humana asociado al consumo de productos avícolas correctamente procesados es reducido, los efectos derivados de los brotes afectan de forma significativa a la cadena de producción, al abastecimiento y al equilibrio económico del sector.

Cuando una explotación detecta un foco de IAAP, los protocolos sanitarios obligan generalmente al sacrificio completo de las aves presentes en la granja, independientemente del número inicial de animales afectados. Este procedimiento busca evitar la expansión del virus, pero genera importantes consecuencias económicas y logísticas. En escenarios donde múltiples explotaciones resultan afectadas simultáneamente, pueden producirse alteraciones en la producción nacional, incrementos de precios y dependencia de importaciones.

1.1. Influenza Aviar Altamente Patógena.

La IAAP se diferencia de las variantes de baja patogenicidad por la gravedad clínica y la elevada tasa de mortalidad que provoca en aves domésticas y silvestres. El primer gran episodio moderno asociado al salto interespecie se documentó en Hong Kong en 1997 con la cepa H5N1, marcando un punto de inflexión en la vigilancia epidemiológica internacional [1].

Desde el punto de vista analítico, uno de los principales desafíos asociados al estudio de este virus es su elevada capacidad de mutación. Los virus influenza poseen ARN monocatenario y carecen de mecanismos eficientes de corrección durante la replicación, lo que favorece una evolución rápida y continua. Esta variabilidad genética implica que los patrones epidemiológicos pueden modificarse con el tiempo, dificultando la estabilidad de los modelos predictivos utilizados para el estudio de la enfermedad, entre ellos los modelos epidemiológicos compartimentales (como SIR o SEIR), los modelos estadísticos espacio-temporales y los modelos basados en técnicas de minería de datos y aprendizaje automático destinados al análisis y la predicción de brotes [2].

Las proteínas hemaglutinina (H) y neuraminidasa (N) determinan los distintos subtipos virales. Entre ellos, los subtipos H5 y H7 presentan especial interés debido a su asociación frecuente con formas altamente patógenas. Sin embargo, no todos los virus pertenecientes a estos grupos son necesariamente altamente patógenos, ya que la virulencia depende de secuencias específicas capaces

de facilitar la infección sistémica [3].

Las aves acuáticas silvestres actúan como reservorio natural del virus. En muchas ocasiones presentan infecciones asintomáticas mientras continúan excretando partículas virales, permitiendo la dispersión geográfica del patógeno mediante rutas migratorias. Este fenómeno resulta especialmente relevante en estudios basados en minería de datos, ya que las migraciones pueden actuar como mecanismo estructural detrás de ciertos patrones espaciales y temporales [4], [5], [6].

España constituye un escenario particularmente interesante debido a su posición geográfica estratégica dentro de rutas migratorias euroafricanas y a la existencia de importantes humedales utilizados como áreas de descanso por aves acuáticas migratorias. Además, la diversidad climática y ecológica de la Península Ibérica proporciona un entorno adecuado para estudiar posibles diferencias regionales en la dinámica de propagación [7].

1.1.1. Factores epidemiológicos relevantes.

La progresión clínica de la enfermedad en aves de corral puede ser extremadamente rápida, alcanzando tasas de mortalidad cercanas al 100 % en cuestión de horas o días. Esta velocidad dificulta la detección temprana y favorece la propagación antes de la implementación de medidas de control.

Los sistemas de vigilancia presentan además limitaciones derivadas de retrasos en la notificación, diferencias regionales en los protocolos de reporte y variabilidad en la calidad de los datos disponibles. Desde una perspectiva de análisis, estas limitaciones pueden introducir sesgos temporales y espaciales que deben ser considerados durante la fase de limpieza y preparación de datos.

La estacionalidad constituye otro elemento especialmente relevante. En Europa, los brotes suelen concentrarse durante otoño e invierno, coincidiendo con movimientos migratorios de aves acuáticas. Este comportamiento sugiere la existencia de patrones temporales susceptibles de ser identificados mediante técnicas de análisis de series temporales y modelado predictivo [8], [9], [10], [11].

Asimismo, la densidad de explotaciones avícolas influye directamente sobre la velocidad de propagación. Regiones con alta concentración de granjas pueden facilitar la expansión entre explotaciones cercanas, especialmente cuando coinciden factores como elevada movilidad, bioseguridad insuficiente o proximidad a humedales.

En el caso de España, otro aspecto relevante es la variabilidad existente entre los modelos de producción avícola, la densidad de explotaciones y los niveles de bioseguridad. Estas diferencias pueden introducir factores explicativos adicionales susceptibles de incorporarse en modelos predictivos de dispersión, como los enfoques de metapoblación o las adaptaciones del marco SIR aplicadas a poblaciones aviares [12].

1.1.2. Factores de dispersión.

Las rutas migratorias de aves acuáticas representan uno de los principales mecanismos de dispersión del virus a escala continental. España ocupa una posición estratégica dentro de corredores migratorios entre Europa y África, especialmente a través de la ruta del Atlántico Oriental y del corredor Mediterráneo [13].

Determinados humedales actúan como puntos de concentración de aves migratorias y adquieren un interés especial dentro del análisis epidemiológico. Espacios como Doñana, el Delta del Ebro, las Tablas de Daimiel o la Albufera de Valencia concentran grandes poblaciones de aves durante períodos migratorios, pudiendo convertirse en zonas relevantes para la detección de patrones espaciales [14].

El clima también influye sobre la persistencia ambiental del virus. Las temperaturas bajas favorecen su supervivencia, mientras que condiciones cálidas y húmedas aceleran su degradación. Como consecuencia, la distribución temporal de brotes suele presentar cierta estacionalidad [15].

Junto a los factores naturales, la actividad humana introduce elementos adicionales de complejidad. El comercio de aves vivas, mercados avícolas, transporte de animales y diferencias en medidas de bioseguridad pueden generar brotes alejados de las rutas migratorias esperadas. En términos de análisis de datos, esto podría reflejarse en anomalías espaciales difíciles de explicar únicamente mediante variables ambientales [16].

1.2. Relevancia del análisis predictivo.

El impacto económico de la influenza aviar es considerable y trasciende las pérdidas directas derivadas del sacrificio de animales. Los brotes generan costes asociados a desinfección de instalaciones, paralización de la producción, restricciones comerciales y pérdida de competitividad internacional [17].

Brotes en Europa y Estados Unidos supusieron el sacrificio de decenas de millones de aves y pérdidas económicas valoradas en miles de millones de euros y dólares. Bajo este contexto, incluso pequeñas mejoras en la capacidad de detección temprana o identificación de áreas de riesgo podrían traducirse en beneficios económicos y sanitarios relevantes [18].

Además del impacto económico, existe preocupación constante por el potencial zoonótico del virus. Aunque la transmisión sostenida entre humanos no se produce actualmente, múltiples eventos de salto de especie documentados en mamíferos sugieren una capacidad de adaptación que mantiene activa la vigilancia internacional [19].

Las estrategias actuales de vigilancia continúan siendo mayoritariamente reactivas. Habitualmente dependen de la aparición de síntomas y de la posterior confirmación por parte del laboratorio, momento en el cual el virus puede haberse dispersado ampliamente. Bajo estas circunstancias, modelos predictivos como los basados en *Random Forest* o Regresión Logística aplicados al análisis de patrones epidemiológicos pueden actuar como herramientas complementarias para optimizar recursos de vigilancia y priorizar áreas de riesgo [1], [7], [20], [21], [22].

- Identificación temprana de zonas potencialmente vulnerables.
- Refuerzo preventivo de medidas de bioseguridad.
- Priorización de recursos de vigilancia epidemiológica.
- Reducción de pérdidas económicas asociadas a brotes extensivos.
- Mejora de la capacidad de respuesta ante eventos emergentes.

1.3. Motivación del TFG.

En los últimos años, el crecimiento exponencial de los datos generados por sistemas de vigilancia, organismos internacionales e instituciones científicas ha transformado numerosos ámbitos del conocimiento. Sin embargo, la mera disponibilidad de grandes volúmenes de información no garantiza la obtención de conocimiento útil, especialmente cuando los datos proceden de fuentes heterogéneas, presentan niveles de calidad dispares o describen fenómenos dinámicos y complejos. En este contexto, la minería de datos y el aprendizaje automático se han consolidado como herramientas fundamentales para identificar patrones, descubrir relaciones no evidentes y apoyar procesos de análisis y toma de decisiones basados en evidencias. La capacidad para transformar grandes volúmenes de datos en conocimiento útil constituye, en la actualidad, uno de los principales retos de la Ingeniería Informática y de la Ciencia de Datos.

La aplicación de estas metodologías resulta especialmente pertinente en problemas en los que intervienen múltiples factores espaciales, temporales y ambientales, como ocurre en el ámbito de la vigilancia epidemiológica. La capacidad de integrar información procedente de diversas fuentes y analizar su comportamiento conjunto permite explorar hipótesis, detectar regularidades y evaluar en qué medida los datos disponibles son capaces de describir fenómenos cuya dinámica resulta difícil de modelizar mediante enfoques tradicionales. Desde esta perspectiva, incluso la identificación de patrones parciales o la ausencia de correlaciones robustas constituye un resultado relevante, ya que aporta información sobre las limitaciones, la calidad y el potencial analítico de los propios datos.

No obstante, los patrones observados pueden verse condicionados por factores externos que escapen al propio proceso analítico, tales como variaciones climáticas, modificaciones en las rutas migratorias, desigual calidad de las fuentes o cambios en las prácticas de producción avícola. Asimismo, los sistemas de vigilancia y notificación pueden introducir sesgos derivados de la disponibilidad, cobertura o granularidad de la información, lo que obliga a interpretar los resultados desde una perspectiva metodológica y probabilística, evitando establecer relaciones causales que no puedan ser respaldadas por la evidencia disponible [10].

Este Trabajo Fin de Grado, desarrollado en colaboración con investigadores del Centro de Investigación en Sanidad Animal perteneciente al INIA dependiente del CSIC (INIA-CSIC), emplea como caso de estudio la Influenza Aviar Altamente Patógena (IAAP). Para ello, se utilizan conjuntos de datos reales facilitados por esta institución, sobre los que se aplican técnicas de minería de datos, aprendizaje automático y modelización predictiva.

Sin embargo, el interés principal del trabajo no reside en el estudio epidemiológico de la enfermedad como objetivo final, sino en la aplicación de metodologías propias de la Ingeniería Informática para el tratamiento y análisis de información compleja. Desde esta perspectiva, la IAAP constituye un escenario de validación especialmente adecuado debido a la diversidad geográfica, temporal y taxonómica de los datos disponibles, lo que convierte este planteamiento en una aproximación potencialmente extrapolable a otros dominios donde sea necesario integrar, analizar y extraer conocimiento a partir de grandes volúmenes de información heterogénea.

Bajo este enfoque, las interpretaciones relacionadas con el contexto epidemiológico se incorporan únicamente como elemento de contextualización de los resultados obtenidos. El propósito del trabajo es analizar hasta qué punto las herramientas computacionales pueden contribuir a extraer conocimiento a partir de datos reales, identificar patrones relevantes y apoyar futuros procesos de investigación y toma de decisiones, manteniendo en todo momento una perspectiva metodológica coherente con el ámbito de la Ingeniería Informática.

2. Objetivos.

El objetivo general de este Trabajo Fin de Grado es identificar y caracterizar patrones espaciales, temporales y taxonómicos asociados a los brotes de Influenza Aviar Altamente Patógena (IAAP), así como evaluar la capacidad de las variables geográficas y ecológicas para describir la relación entre los brotes registrados en aves silvestres y la aparición de casos en mamíferos.

La consecución de este objetivo general requiere abordar el problema desde diferentes perspectivas complementarias, relacionadas con la calidad de los datos, el análisis de sus características, la identificación de relaciones entre variables y la valoración del alcance real de los resultados obtenidos. Para ello, se plantean los siguientes objetivos específicos.

Construir, mediante un proceso ETL (extracción, transformación y carga), un *dataset* analítico único a partir de la integración de fuentes heterogéneas de información epidemiológica y geográfica, resolviendo las diferencias de formato y de sistema de referencia entre ellas, de modo que el conjunto resultante quede preparado para su análisis exploratorio y modelado posterior.

Caracterizar la distribución taxonómica, espacial y temporal de los brotes registrados mediante análisis exploratorio de datos (EDA), con el fin de obtener una visión global del comportamiento de los datos y una primera aproximación a la dinámica del fenómeno estudiado.

Evaluar el grado de asociación espacial entre los brotes registrados en aves silvestres y los casos detectados en mamíferos, mediante el análisis de correlación entre sus respectivas distribuciones de densidad geográfica.

Identificar las variables geográficas y ecológicas con mayor capacidad predictiva mediante el análisis de importancia de variables (feature importance) generado por el modelo de clasificación desarrollado.

Evaluar, sin reentrenamiento, el grado de generalización del modelo construido a partir de información global al aplicarlo al subconjunto de brotes correspondiente a España, valorando la utilidad de la información regional para la caracterización de los brotes en dicho contexto.

3. Estado del arte.

En esta sección se presenta un breve recorrido por el uso de técnicas de minería de datos y *machine learning* en el apoyo a la toma de decisiones por parte de gobiernos y otros organismos. Se mencionan alguno de los hitos que se han terminado convirtiendo en iniciativas y se cierra esta sección indicando los límites a los modelos y herramientas actuales.

3.1. Predicción de proliferación de enfermedades.

Cuando se revisa la literatura científica sobre influenza aviar, lo que más llama la atención es cómo ha cambiado el enfoque de investigación en los últimos tiempos. Los trabajos de los años noventa puede tildarse de artesanales; estos constaban de una vigilancia veterinaria clásica y métodos epidemiológicos descriptivos. Solo después de los primeros casos graves de H5N1 en el sudeste asiático, el enfoque y recursos dedicados empezó a cambiar [23].

En este caso, este aspecto es importante porque muestra la evolución metodológica del campo. Los sistemas de vigilancia de entonces dependían de redes de notificación bastante fragmentadas, protocolos de muestreo dispares y comunicación entre instituciones que no siempre funcionaba bien. No había nada parecido a las plataformas digitales unificadas que se utilizan en la actualidad [20].

Los primeros modelos predictivos eran relativamente sencillos y se apoyaban en análisis estadísticos descriptivos orientados a identificar correlaciones entre los brotes y factores ambientales como la temperatura o la humedad. Aunque útiles en un primer momento, estos enfoques dejaban fuera buena parte de la complejidad real del fenómeno, incluyendo las interacciones ecológicas, los factores socioeconómicos o las rutas migratorias de las aves.

La recopilación de datos se realizaba de forma manual mediante muestreos presenciales en granjas y mercados de aves vivas. Estos registros se almacenaban en bases de datos locales que apenas se integraban con sistemas nacionales o internacionales, lo que generaba una fragmentación significativa y retrasaba la detección temprana de brotes emergentes.

Un problema adicional era la falta de criterios uniformes entre países para determinar qué se consideraba un brote. Cada sistema de vigilancia aplicaba sus propias definiciones, lo que generaba diferencias en la forma de registrar y notificar los casos. Esta falta de estandarización dificultaba la construcción de modelos comparables entre regiones y añadía incertidumbre al análisis, especialmente cuando los datos eran incompletos o contenían inconsistencias relevantes.

3.2. Modelos matemáticos. Técnicas de análisis exploratorio.

Después de los brotes grandes de 2004-2006, el mundo empezó a tomar conciencia del problema. Fue entonces cuando organizaciones como la FAO, la OIE y la OMS establecieron marcos de cooperación más sólidos que facilitaron el intercambio de datos clínicos, genómicos y ambientales. Cabe señalar que no todos los estudios coinciden en este punto, pero la mayoría identifica este período como un momento de inflexión [6].

Aun así, las herramientas disponibles seguían siendo rudimentarias. Las bases de datos estaban dispersas, la información viajaba por canales administrativos lentos, y los análisis automatizados o la visualización geoespacial eran prácticamente inexistentes para la mayoría de investigadores.

Durante esta etapa surgieron los primeros modelos matemáticos formales aplicados a la influenza aviar. Los epidemiólogos comenzaron a adaptar modelos compartimentales clásicos, como el modelo SIR (Susceptible, Infectado, Recuperado), para su aplicación específica en poblaciones de aves. Estos enfoques incorporaban factores como la densidad poblacional, las tasas de contacto entre individuos y la duración de los períodos infecciosos [24].

Los modelos de metapoblación también ganaron importancia durante estos años. Estos enfoques reconocían algo que parece obvio pero que antes se ignoraba: las poblaciones de aves no son bloques homogéneos, sino estructuras complejas organizadas en subpoblaciones conectadas por movimientos migratorios. En varios trabajos recientes se ha observado que esta perspectiva cambió completamente la forma de entender la dispersión viral geográfica [5].

Un momento clave fue la incorporación de sistemas de información geográfica (SIG). De repente, los investigadores podían visualizar brotes en mapas, hacer análisis espaciales sistemáticos, identificar esas zonas que llamaban "puntos calientes". Normalmente estos puntos coincidían con humedales importantes en rutas migratorias principales.

El análisis mediante series temporales también cobró relevancia en este período. Las técnicas ARIMA se usaron para capturar patrones estacionales de brotes. Los análisis revelaron que muchos brotes seguían ciclos anuales predecibles, relacionados directamente con las migraciones de aves acuáticas. Era como descubrir que había un reloj biológico detrás de todo esto.

Paralelamente se desarrollaron unas técnicas de análisis exploratorio específicas para el estudio de los datos epidemiológicos. El análisis de conglomerados espaciotemporales permitía identificar agrupaciones de casos que no se veían a simple vista. Estos análisis son muy útiles para detectar brotes incipientes antes de que se propaguen [25].

3.3. Aplicaciones de *machine learning* en epidemiología.

A partir de 2010, con irrupción del *big data* y mejor acceso a registros digitales, el enfoque cambió radicalmente: de describir lo que había pasado a predecir lo que iba a pasar.

Los primeros algoritmos de *machine learning* aplicados adoptaron un enfoque conservador, utilizando conjuntos de datos limitados y un reducido número de variables de riesgo bien caracterizadas. Se emplearon técnicas de clasificación supervisada *random forest* y *support vector machines* para predecir probabilidades de brotes en granjas individuales. A pesar de estas limitaciones, estos algoritmos ya mostraban su potencial para integrar múltiples factores de riesgo y mejorar la capacidad predictiva de los modelos [22], [26].

Las redes neuronales artificiales permitieron modelar relaciones no lineales e interacciones entre variables de una complejidad superior a la abordada habitualmente en los primeros enfoques predictivos. En epidemiología esto es especialmente relevante, ya que las interacciones entre factores ambientales, ecológicos y socioeconómicos rara vez son simples. Los primeros modelos de redes neuronales para influenza aviar ya mostraban mejoras considerables en precisión.

El salto cualitativo llegó con *deep learning* y las redes neuronales LSTM (*Long Short Term Memory*). Estas redes tienen una elevada capacidad para capturar patrones temporales complejos en series de datos de brotes epidemiológicos. Además, pueden aprender dependencias a largo plazo entre los datos, permitiendo detectar relaciones temporales que resultan difíciles de identificar mediante otros enfoques más tradicionales. En este caso, esta característica resulta especialmente interesante, ya que las redes LSTM pueden conservar información relevante de etapas anteriores de la secuencia para reconocer patrones separados por intervalos temporales amplios [25].

Los modelos *ensemble* también han ganado protagonismo dentro del ámbito de la minería de datos y el aprendizaje automático debido a su capacidad para mejorar la robustez y el rendimiento de las predicciones. Entre ellos, algoritmos como *Gradient boosting*, *Random Forest* han obtenido resultados satisfactorios en aplicaciones relacionadas con la vigilancia epidemiológica, especialmente cuando se trabaja con conjuntos de datos que incluyen variables de distinta naturaleza.

Algo particularmente innovador ha sido la integración de datos genómicos. Los algoritmos pueden analizar secuencias virales para identificar mutaciones asociadas con mayor virulencia o capacidad de transmisión interespecie. Esto facilita análisis filogenéticos automatizados que predicen cómo va a evolucionar el virus.

El procesamiento de lenguaje natural también encontró su sitio aquí. El análisis automatizado de reportes veterinarios, noticias, redes sociales puede dar señales tempranas de brotes antes de que lleguen a canales oficiales. Esta “vigilancia digital” complementa muy bien los sistemas tradicionales.

Los algoritmos de *clustering* no supervisado han demostrado utilidad para identificar patrones ocultos en datos epidemiológicos. *K-means*, *clustering* jerárquico y otros, pueden agrupar brotes con características similares y revelar tipologías que no son evidentes de otra manera.

Estos métodos no solo optimizan la vigilancia, también ayudan a entender mejor cómo la dinámica de transmisión se ve afectada por factores socioeconómicos y ecológicos complejos.

3.4. Plataformas actuales y infraestructuras de datos.

La situación actual es completamente diferente a la de hace 20 años, existiendo un ecosistema robusto de plataformas abiertas que consolidan información global sobre influenza aviar. Las principales son *GISAID* para secuencias genómicas, *FAO EMPRES-i+* para vigilancia epidemiológica internacional y *OIE-WAHIS* para notificaciones oficiales de brotes. *GISAID* ha supuesto un punto de inflexión al permitir que investigadores de todo el mundo compartan secuencias virales casi en tiempo real, con análisis filogenéticos ejecutados automáticamente que facilitan el seguimiento de la evolución viral y la identificación de linajes emergentes con potencial pandémico. Por su parte, *FAO EMPRES-i+* representa la evolución natural de los sistemas tradicionales de notificación, integrando análisis de riesgo automatizados capaces de detectar patrones espaciotemporales sospechosos y generar alertas para autoridades veterinarias. *OIE-WAHIS* completa este ecosistema proporcionando el marco legal y técnico para la notificación obligatoria de enfermedades animales, cuyo sistema de codificación estandarizada ha resuelto gran parte de los problemas de heterogeneidad mencionados anteriormente, haciendo posibles los análisis comparativos globales [2], [6].

Especialmente destacables son las iniciativas académicas de código abierto, que han democratizado el acceso a análisis epidemiológicos sofisticados mediante tableros de control geoespaciales, sistemas de alerta temprana basados en machine learning y repositorios de datos abiertos. *HealthMap* y *ProMED* son ejemplos representativos: proporcionan visualizaciones interactivas de brotes en tiempo real procesando información de múltiples fuentes para generar mapas de riesgo actualizados. En este mismo ámbito, plataformas como *GitHub* y *Zenodo* han resultado fundamentales para la reproducibilidad científica, poniendo a disposición de la comunidad global *datasets*, códigos de análisis y modelos predictivos, lo que ha acelerado significativamente el ritmo de innovación en el campo.

Finalmente, dos tendencias emergentes apuntan hacia la siguiente frontera dentro del análisis epidemiológico. Por un lado, los sistemas de alerta temprana basados en inteligencia artificial son capaces de procesar volúmenes enormes de datos heterogéneos e identificar señales débiles que podrían indicar brotes emergentes. Por otro, la integración de datos de teledetección satelital, que proporciona información sobre cambios en el uso del suelo, condiciones climáticas y patrones de

migración, permite generar predicciones de riesgo acotadas geográficamente con una precisión hasta hace poco inalcanzable.

3.5. Desafíos actuales y limitaciones.

A pesar de estos avances, persisten desafíos importantes en la aplicación de *machine learning* a epidemiología de influenza aviar. El principal problema, es la calidad y completitud de los datos disponibles. Muchos brotes, especialmente en países en desarrollo, siguen sin reportarse o llegan con retrasos significativos [10].

La heterogeneidad entre sistemas de vigilancia de diferentes países sigue siendo problemática. Protocolos de muestreo diferentes, criterios de notificación dispares, capacidades de los laboratorios para obtener y analizar muestras es realmente variables; todo esto resulta en *datasets* complicados de integrar y comparar.

Los problemas de escalabilidad temporal también son relevantes. Muchos modelos funcionan bien para predicciones a corto plazo pero se degradan cuando intentas extender el horizonte temporal. Esto es especialmente problemático para planificación de políticas de salud pública.

La adopción de modelos con gran capacidad predictiva presenta una dificultad añadida derivada de su carácter opaco. Aunque pueden alcanzar niveles de precisión elevados, no siempre es posible conocer los elementos que intervienen en la generación de cada predicción. Esta falta de claridad reduce su aceptación entre epidemiólogos y responsables de políticas, que necesitan disponer de información interpretable para apoyar la toma de decisiones.

El problema de eventos raros es otro desafío metodológico importante. Los brotes de influenza aviar, aunque devastadores cuando ocurren, son relativamente infrecuentes en tiempo y espacio. Esta escasez de eventos positivos complica el entrenamiento de modelos supervisados.

La validación de modelos en epidemiología tiene sus peculiaridades. Los sistemas epidemiológicos son dinámicos, así que los modelos necesitan re-evaluaciones de manera constante. Además, las consideraciones éticas limitan las posibilidades de validación prospectiva controlada.

Los sesgos de selección en datos de vigilancia pueden afectar seriamente al rendimiento de los modelos. La vigilancia tiende a concentrarse en áreas de alto riesgo percibido, creando representaciones distorsionadas de la distribución real de la enfermedad.

Finalmente, está el tema de la traslación de modelos. Un modelo desarrollado para Europa puede no funcionar en Asia o África debido a diferencias en sistemas de producción, patrones migratorios, factores socioeconómicos. Cabe señalar que no todos los estudios coinciden en este punto, pero

es una limitación reconocida que reduce la utilidad de modelos individuales para vigilancia global coordinada.

3.6. Fuentes de consulta no citadas.

En el Anexo A se recogen las fuentes de consulta de carácter divulgativo y periodístico (principalmente artículos de prensa generalista y sitios web institucionales o corporativos) que, si bien no han sido citadas de forma directa en el texto principal, han contribuido a la contextualización del dominio de estudio durante las fases iniciales del trabajo.

4. Metodología.

En este trabajo se aplican técnicas de minería de datos y aprendizaje automático sobre información relacionada con brotes de gripe aviar, variables ecológicas y datos geográficos. El proceso metodológico no se limita a la aplicación de algoritmos de clasificación, sino que abarca todas las fases necesarias para transformar fuentes de información heterogéneas y dispersas en un conjunto de datos coherente, estructurado y utilizable desde un punto de vista analítico. Estas fases, que se describen con detalle en los apartados siguientes, comprenden desde el preprocesado e integración de las fuentes de datos hasta la construcción, evaluación y discusión de los modelos de aprendizaje automático empleados.

La figura 1 recoge de forma esquemática el conjunto de estas fases, ilustrando el proceso metodológico seguido para el desarrollo de este TFG.




Figura 1. Fases del proceso metodológico: desde el preprocesado ETL hasta la evaluación y discusión de los modelos de aprendizaje automático.
Fuente: Elaboración propia

La naturaleza de los datos disponibles introduce una serie de dificultades que condicionan directamente la metodología adoptada. La información no procede de una única base de datos homogénea, sino de múltiples conjuntos generados por organismos y herramientas diferentes, lo que implica trabajar con formatos variados, estructuras no uniformes y niveles de calidad distintos entre fuentes. A esto se suma que parte de la información pertenece al ámbito de los Sistemas de Información Geográfica, incorporando geometrías espaciales, polígonos y capas cartográficas cuya integración requiere procedimientos específicos de tratamiento y validación. Esta combinación entre datos epidemiológicos y variables espaciales constituye uno de los elementos centrales del enfoque metodológico, ya que los registros de brotes deben ser contextualizados dentro de su entorno ambiental y territorial mediante operaciones de análisis geoespacial.

El proceso de construcción del *dataset* final tiene además un carácter marcadamente iterativo. Lejos de seguir una secuencia estrictamente lineal, muchas decisiones adoptadas durante las fases de preparación e integración estuvieron condicionadas por resultados obtenidos en etapas posteriores del análisis. La detección de variables redundantes, la identificación de problemas de cobertura o la necesidad de reorganizar determinadas categorías taxonómicas requirieron revisar y ajustar distintas partes del proceso conforme avanzaba el desarrollo del proyecto. Este comportamiento resulta especialmente habitual cuando se trabaja con datos procedentes de organismos externos, que incorporan con frecuencia inconsistencias, errores de representación y limitaciones estructurales que obligan a combinar criterios técnicos con decisiones analíticas orientadas a preservar la coherencia global del estudio.

Las secciones siguientes describen de forma detallada las distintas fases que componen el proceso metodológico, recogidas de forma esquemática en la figura 1. La fase F1 (Preprocesado ETL) comprende, en primer lugar, un análisis inicial de comprensión y validación de los datos disponibles; a continuación, el proceso de preparación e integración mediante técnicas ETL y operaciones de análisis espacial orientadas a enriquecer los registros epidemiológicos originales; y, sobre esta base, la construcción del *dataset* analítico definitivo, resultado de la selección y transformación de las variables consideradas más relevantes para el problema planteado. A partir de dicho *dataset*, la fase F2 (Análisis exploratorio) aborda el estudio de los patrones temporales y geográficos mediante visualización y el cálculo de coeficientes de correlación de Pearson y Spearman entre los patrones espaciales de los brotes en aves y en mamíferos. Estos resultados se interpretan en la fase F3 (Interpretación EDA), con el objetivo de analizar las posibles relaciones entre el contexto geográfico de los brotes y la clasificación taxonómica de las especies afectadas, así como de documentar los hallazgos y limitaciones del análisis exploratorio. Finalmente, la metodología incorpora una fase de *Machine Learning* orientada al análisis predictivo, dividida a su vez en dos etapas. En la fase F4 (Modelos de

ML) se seleccionan, entrenan y evalúan un modelo principal de clasificación y un modelo de contraste, ambos sobre el mismo conjunto de datos y bajo idénticas condiciones experimentales: concretamente, *Random Forest* como modelo principal y la Regresión Logística como modelo de contraste. En la fase F5 (Discusión ML) se comparan los resultados de ambos modelos mediante métricas de clasificación, con el fin de identificar el algoritmo con mejor capacidad predictiva, que posteriormente se utiliza para generar las estimaciones sobre el conjunto de datos correspondiente al territorio español.

Antes de presentar la metodología empleada en este trabajo, resulta pertinente situarlo dentro de un marco metodológico reconocido. La comprensión de este marco facilita la interpretación de las decisiones técnicas descritas en los apartados posteriores, por lo que se introduce brevemente el modelo CRISP-DM.

El modelo CRISP-DM (*Cross-Industry Standard Process for Data Mining*) se ha consolidado como el estándar metodológico más extendido en proyectos de minería de datos. Su adopción generalizada en ámbitos industriales, científicos y académicos se debe a su carácter neutral respecto a herramientas, dominios y técnicas, lo que permite aplicarlo a una amplia variedad de problemas analíticos. A diferencia de otros enfoques más prescriptivos, CRISP-DM propone una estructura flexible organizada en seis fases: comprensión del negocio, comprensión de los datos, preparación de los datos, modelado, evaluación y despliegue, concebidas de forma iterativa, lo que refleja la naturaleza exploratoria y no lineal del análisis de datos. Esta forma de trabajar, en la que los resultados de una fase pueden motivar el retorno a fases anteriores, es la que ha guiado de hecho la construcción del *dataset* analítico de este trabajo, tal como se ha descrito anteriormente.

La elección de CRISP-DM como referencia conceptual en este trabajo responde a dos motivos principales. En primer lugar, proporciona una terminología común y una secuencia lógica que facilitan la comunicación del proceso analítico, especialmente en contextos académicos donde la claridad metodológica es un criterio de evaluación explícito. En segundo lugar, su énfasis en la comprensión del contexto y de los datos encaja de forma natural con proyectos basados en fuentes heterogéneas, como es el caso de este estudio, donde la calidad y coherencia de la información condicionan directamente la validez de los resultados.

Frente a otros modelos alternativos, como SEMMA (*Sample, Explore, Modify, Model, Assess*) o los flujos de trabajo específicos de determinadas herramientas, CRISP-DM ofrece una visión más completa del ciclo de vida del proyecto, incorporando fases previas al modelado y posteriores a la evaluación. Esta amplitud resulta especialmente útil en entornos donde el objetivo no es únicamente construir un modelo predictivo, sino documentar y justificar las decisiones tomadas durante todo el proceso de análisis.

4.1. Herramientas y entorno de implementación.

El desarrollo del proyecto se llevó a cabo sobre una máquina virtualizada con sistema operativo Linux Ubuntu 24.04 LTS. El entorno fue configurado con 40 GB de almacenamiento, 8 GB de memoria RAM y 2 vCPU, recursos considerados adecuados para la ejecución de tareas de procesamiento, transformación y análisis de datos, así como para la ejecución de algoritmos de minería de datos y modelos de aprendizaje automático. La utilización de un entorno virtualizado permitió disponer de una infraestructura aislada, estable y reproducible, facilitando además la gestión de dependencias software y la replicabilidad de los experimentos realizados durante el desarrollo del proyecto.

La implementación de la solución se realizó utilizando Python 3.13, seleccionado por su estabilidad, rendimiento y compatibilidad con el ecosistema científico orientado al análisis de datos y aprendizaje automático. Como entorno de desarrollo integrado se empleó Visual Studio Code, debido a su ligereza, soporte multiplataforma e integración con herramientas de depuración, control de versiones y gestión de entornos virtuales. Esta combinación tecnológica permitió centralizar el desarrollo, ejecución y validación de los distintos procesos analíticos y experimentales desarrollados a lo largo del proyecto.

Para las tareas de manipulación, limpieza y transformación de datos se utilizaron principalmente las bibliotecas *pandas* y *numpy*, ampliamente consolidadas en entornos de análisis de datos por su eficiencia en el tratamiento de estructuras tabulares y operaciones numéricas de alto rendimiento. La representación visual de la información y el análisis del *dataset* se apoyaron en *matplotlib* y *seaborn*, herramientas que facilitaron la generación de gráficos estadísticos, visualizaciones comparativas y representaciones orientadas a la interpretación de patrones y tendencias presentes en los datos analizados. Asimismo, se emplearon módulos adicionales de *matplotlib* para la personalización avanzada de gráficos y la generación de animaciones orientadas al análisis visual de resultados.

En el ámbito del análisis espacial y estadístico, se incorporaron bibliotecas especializadas como *geopandas*, *geodatasets* y funcionalidades de *shapely*, utilizadas para el tratamiento y análisis de información geoespacial. Del mismo modo, las herramientas incluidas en *scipy* permitieron aplicar técnicas estadísticas avanzadas, cálculos de densidad y procedimientos analíticos complementarios al proceso de minería de datos. Estas tecnologías proporcionaron soporte para la construcción, validación y comparación de distintos enfoques analíticos y modelos predictivos, permitiendo evaluar comportamientos, detectar patrones y contrastar resultados obtenidos mediante diferentes técnicas de procesamiento y análisis de datos. Adicionalmente, se utilizó *openpyxl* como motor de lectura y procesamiento de archivos en formato Excel (.xlsx), facilitando la integración de fuentes de información heterogéneas dentro del flujo ETL desarrollado.

4.1.1. Código fuente y recursos complementarios.

El código fuente del proyecto, junto con otros materiales generados durante su desarrollo, están disponibles en el repositorio público habilitado para este trabajo. El repositorio se organiza en tres carpetas según el tipo de recurso: código, datos e imágenes, y puede consultarse a través de las siguientes direcciones:

- Repositorio oficial del proyecto, que incluye código, datos y documentación complementaria:
<https://github.com/frankaq2026/publico-u1/tree/main/proyecto1>
- Portal web del proyecto para la consulta estructurada de los recursos:
<https://frankaq2026.github.io/publico-u1/?path=proyecto1>

Los *scripts* de Python desarrollados para las distintas fases del trabajo (ETL, análisis exploratorio, análisis geoespacial, modelado y visualización de resultados) no se recogen en el cuerpo de la memoria por su extensión. No obstante, en el Anexo B se incluyen los fragmentos de código correspondientes a la fase de verificación y diagnóstico de las fuentes de datos, junto con los errores detectados durante los primeros intentos de lectura de los ficheros originales y las soluciones adoptadas para su correcta interpretación.

Los ficheros de datos originales facilitados por el INIA-CSIC no se han incluido en el repositorio, ya que están sujetos a restricciones que impiden su redistribución. Para más información sobre licencias y procedimientos de acceso a cada fuente, véase el Anexo Anexo D de este documento. Dicho anexo detalla las condiciones específicas de cada organismo proveedor, cuyo contenido se reproduce íntegramente en el fichero *README* del directorio */datos* del repositorio.

Los resultados que se presentan a lo largo de este trabajo son completamente reproducibles a partir del código disponible en el repositorio, siempre que se cuente con los ficheros de datos originales en los términos descritos.

4.2. Análisis inicial y comprensión de la información.

En este trabajo se toma como referencia el modelo CRISP-DM (*Cross-Industry Standard Process for Data Mining*), un marco metodológico ampliamente contrastado y utilizado en proyectos de análisis y minería de datos. Su función aquí es servir como guía conceptual para estructurar el proceso analítico. En este punto se adopta específicamente la idea de comprensión de los datos, entendida como la revisión preliminar de las fuentes de información disponibles antes de abordar cualquier fase de transformación o modelado.

En este momento del TFG se adopta la idea central del modelo CRISP-DM relativa a la comprensión de los datos, entendida como la revisión inicial de las fuentes de información disponibles. Este enfoque permite examinar la estructura, coherencia y calidad de los conjuntos de datos antes de aplicar cualquier procedimiento de transformación o modelado, garantizando que la información sea adecuada para los análisis posteriores.

La necesidad de este análisis previo resulta especialmente relevante en el contexto de este proyecto, dado que los datos proceden de fuentes heterogéneas generadas por organismos y herramientas distintas. Esta diversidad introduce variaciones en el formato, la codificación y la interpretación semántica de ciertos campos, aspectos que deben identificarse y resolver antes de iniciar el proceso de integración.

El análisis inicial abarca, por tanto, tanto la identificación y caracterización de las fuentes disponibles como la verificación de su calidad e integridad, incluyendo la detección de errores, valores ausentes y problemas de compatibilidad entre *datasets*. En algunos casos, este proceso requirió además una interacción directa con el proveedor de los datos para aclarar ambigüedades o inconsistencias que no podían resolverse de forma autónoma.

Los subapartados siguientes describen en detalle cada una de estas etapas: el preanálisis de las fuentes de datos, la verificación de calidad e integridad de los datos y la rectificación de fuentes realizada tras la consulta con el organismo proveedor.

4.2.1. Preanálisis de las fuentes de datos.

Los investigadores del INIA-CSIC proporcionaron un conjunto inicial de ficheros generados por herramientas de distinta naturaleza, abarcando desde hojas de cálculo hasta sistemas de información geográfica y gestores de bases de datos internacionales. Esta heterogeneidad en el origen de las fuentes anticipa la variabilidad estructural y de formato que caracteriza el proceso de integración posterior.

Para cada uno de los ficheros recibidos se aplicó una secuencia homogénea de pasos de análisis previo, con el objetivo de obtener una visión inicial del contenido, estructura y calidad de la información disponible antes de iniciar cualquier proceso de transformación. En el caso de los conjuntos de datos distribuidos en formato *shapefile*, se trabajó directamente con la información tabular contenida en los ficheros *dbf*, al constituir estos una fuente accesible para las primeras tareas de exploración y validación del procesamiento de datos. Los ficheros que constituyeron el punto de partida del trabajo fueron los siguientes:

- **brotes1.xlsx**: Fichero principal del *dataset* de partida. Recoge la localización y fecha de detección de cada brote registrado, incorporando cuando es posible información sobre la especie afectada y otras características asociadas al animal o mamífero implicado. Constituye el núcleo epidemiológico del conjunto de datos.
- **sites.dbf**: Conjunto de datos distribuido en formato shapefile, del que inicialmente se empleó la información tabular asociada para las tareas de exploración y preprocesado. Contiene información geoespacial de naturaleza similar al conjunto anterior, aunque con un mayor nivel de detalle en la caracterización de las áreas registradas.
- **features_controid_publishedPoint.dbf**: Fichero perteneciente al sistema RAMSAR, que recoge geolocalizaciones de humedales de importancia internacional distribuidos a escala global.
- **riquezaespecies.dbf**: Fichero con codificación propia vinculado temáticamente al anterior. Contiene información sobre índices de riqueza de especies asociados a unidades territoriales de referencia.

4.2.2. Verificación de calidad e integridad de los datos.

La verificación de la calidad de los datos constituye una etapa imprescindible dentro de cualquier proceso de minería de datos. Trabajar con información procedente de fuentes heterogéneas generadas por herramientas y organismos diferentes introduce un riesgo real de encontrar inconsistencias que, de no ser detectadas y corregidas antes de iniciar el análisis, pueden comprometer la validez de los resultados obtenidos. Un conjunto de datos aparentemente completo puede contener errores de codificación, tipos de campo incompatibles, registros duplicados o valores ausentes cuyo impacto solo se hace visible cuando los algoritmos de análisis comienzan a operar sobre ellos. Por este motivo, la verificación previa no es un trámite formal sino una fase con entidad propia dentro del proceso metodológico.

Para llevar a cabo esta verificación se recurrió a funciones propias del lenguaje Python. Sin embargo, la aplicación de los procedimientos estándar de lectura reveló de forma inmediata una primera dificultad: las funciones de lectura por defecto eran incapaces de interpretar correctamente la codificación de determinadas fuentes, generando errores que sugerían que la información, aun siendo accesible, estaba siendo interpretada de forma incorrecta. La solución adoptada consistió en ampliar dichas funciones mediante parámetros específicos de lectura no habituales en el uso convencional, lo que permitió acceder al contenido real de los ficheros parseando los errores de codificación detectados. Este problema inicial, aunque de naturaleza técnica, ilustra bien la clase de dificultades que caracterizan el trabajo con datos reales procedentes de organismos externos.

Una vez resuelta la lectura de las fuentes, se aplicó sobre cada fichero una secuencia homogénea de verificaciones orientadas a evaluar su estructura, contenido y calidad. Los pasos seguidos fueron los siguientes:

- I. *Lectura de datos*. Verifica que el fichero es accesible y que su formato puede ser interpretado sin errores, confirmando que la fuente es procesable antes de continuar.
- II. *Conteo de registros*. Detecta posibles pérdidas, duplicados o truncamientos comprobando que el número de registros coincide con lo esperado para cada fuente.
- III. *Exposición de las primeras líneas*. Confirma que la estructura inicial del fichero (columnas, orden y codificación) es coherente y responde a lo esperado.
- IV. *Exposición de las líneas finales*. Permite identificar cortes abruptos, datos residuales al final del fichero o inconsistencias en el cierre del *dataset*.
- V. *Detección de tipología de campos*. Garantiza que cada columna presenta un tipo de dato compatible con las operaciones posteriores del proceso ETL y del modelado.
- VI. *Detección y corrección de problemas de tipología*. Asegura que tipos de dato erróneos (como fechas mal formateadas o valores numéricos almacenados como cadenas de texto) sean transformados al tipo correcto antes de continuar.
- VII. *Detección de campos vacíos o nulos*. Identifica ausencia de información que pueda tener impacto sobre las decisiones de descarte o limpieza.
- VIII. *Análisis porcentual de valores ausentes*. Cuantifica el peso real de los valores faltantes en cada columna, proporcionando una base objetiva para decidir estrategias de tratamiento: imputación, descarte o mantenimiento condicionado.

La tabla 1 sintetiza los resultados del proceso de verificación de calidad e integridad aplicado a los distintos conjuntos de datos utilizados en el estudio. El sistema de codificación cromática empleado permite distinguir entre incidencias críticas (color rojo), incidencias de severidad media que requieren revisión o tratamiento adicional (color naranja) y ausencia de incidencias relevantes (color verde).

Desde una perspectiva global, el conjunto de datos *RiquezaEspecies.dbf* presenta un comportamiento completamente consistente, sin incidencias detectadas en ninguna de las dimensiones evaluadas. De forma análoga, el conjunto *brotes1.xls* muestra un nivel de calidad elevado, con únicamente incidencias puntuales de carácter leve. En contraste, los conjuntos de datos asociados a fuentes de naturaleza geoespacial, en particular *features_controid_publishedPoint.dbf* y *sites.dbf*, concentran la

Tabla 1. Verificación de calidad e integridad de los datos. Fuente: Elaboración propia.

	brotes1.xls	sites.dbf	features_control publishedPoint.dbf	RiquezaEspecies.dbf
I	●	●	●	●
II	●	●	●	●
III	●	●	●	●
IV	●	●	●	●
V	●	●	●	●
VI	●	●	●	●
VII	●	●	●	●
VIII	●	●	●	●

● Incidencia grave que requiere modificación seria.
 ● Incidencia leve que requiere modificación simple.
 ● Sin incidencias.

mayor parte de las incidencias identificadas, incluyendo tanto problemas de consistencia como de calidad de los datos. Este comportamiento justifica su tratamiento específico en el apartado siguiente del presente trabajo. Para más información puede consultarse el Anexo B.

4.2.3. Rectificación de fuentes.

El proceso de verificación descrito en el apartado anterior permitió identificar un conjunto de inconsistencias que trascendían la capacidad de resolución autónoma del análisis. Más allá de los problemas técnicos de codificación y formato resueltos internamente, determinadas ausencias de información en columnas clave y ambigüedades en la interpretación semántica de ciertos campos hacían inviable continuar el proceso de integración sin conocimiento directo del contexto en que los datos habían sido generados. Esta situación obligó a trasladar los problemas detectados a los investigadores del CSIC, organismo proveedor de las fuentes originales.

Tras analizar las incidencias comunicadas, el INIA-CSIC confirmó que parte de la información contenida en los ficheros iniciales era efectivamente incompleta o no estaba preparada para su uso directo en el contexto de este trabajo. En respuesta, el organismo facilitó una versión revisada de los *datasets* originales junto con indicaciones precisas sobre qué partes debían considerarse válidas para el análisis. Esta revisión incorporó además un fichero adicional no presente en la entrega inicial, ampliando el conjunto de fuentes disponibles. Los ficheros que conforman el conjunto definitivo de datos, tal y como fueron indicados por los investigadores del INIA-CSIC, son los siguientes:

- **brotes1.xlsx:** Fichero principal del *dataset* de partida, núcleo epidemiológico del trabajo. Mantiene su función como fuente de registros de brotes, aunque en esta versión revisada el INIA-CSIC realizó una depuración que afectó principalmente a la eliminación de determinados atributos completos considerados no pertinentes para el análisis.
- **sites:** Áreas Importantes para las Aves (IBA) y Áreas Clave para la Biodiversidad (KBA) a escala mundial, proporcionado por BirdLife International. Contiene 14.011 áreas con su geometría, estado de clasificación y superficie. Respecto a la entrega inicial, la revisión afectó a la codificación de caracteres y al formato de exportación.
- **features_centroid_publishedPoint:** Información sobre humedales de importancia internacional según el Convenio Ramsar, el tratado intergubernamental de referencia para la conservación de humedales a escala global. La revisión afectó igualmente a aspectos de codificación y formato de exportación. Este fichero presentó una problemática que impedía realizar cruce de datos de manera directa (*within*); la causa es que contiene información geométricas de puntos, si un punto cae dentro de un polígono al ser precisamente información de puntos. Pero como se ha mencionado el fichero no contiene información poligonal sino información sobre puntos.
- **riquezaespecies:** contiene información sobre una malla regular de celdas de 10×10 km, utilizada para representar la riqueza de especies en el territorio español. Esta malla está compuesta por unidades cuadradas de 10 km de lado (100 km²), generadas siguiendo una estructura espacial homogénea y posteriormente recortadas para cubrir exclusivamente el ámbito territorial de España. Cada celda dispone de un código identificador, un valor de riqueza de especies y las coordenadas de su centroide en EPSG:4326 (WGS84).
- **IBAs_criteria_included:** Fichero incorporado en esta segunda entrega. El análisis posterior permitió comprobar que contiene registros ya presentes en el fichero *sites.shp*, ya que ambos comparten prácticamente la totalidad de las observaciones. La diferencia es que este fichero incluye únicamente celdas del continente americano e incorpora varias columnas adicionales relacionadas con criterios IBA, que no fueron utilizadas en el estudio al no aportar información relevante para los objetivos del análisis.

La disponibilidad de este conjunto definitivo de ficheros, validado y delimitado por el propio organismo proveedor, establece la base sobre la que se desarrolla el resto del proceso metodológico. La naturaleza heterogénea de las fuentes (combinando registros epidemiológicos tabulares con capas geográficas de distinta cobertura y escala), hace necesario un proceso de integración espacial que permita relacionar entre sí los distintos ficheros. Este proceso se desarrolla en el apartado de la preparación de datos.

4.3. Marco teórico del ETL.

Una vez completada la fase de análisis inicial y rectificadas las fuentes de información con la colaboración del INIA-CSIC, el siguiente paso metodológico consiste en someter los datos disponibles a un proceso de preparación y transformación que los haga aptos para su uso en el análisis posterior. Este proceso se conoce en el ámbito de la minería de datos y los sistemas de información como ETL, acrónimo del inglés *Extract, Transform, Load*, y constituye una de las fases más características y relevantes dentro de cualquier proyecto de tratamiento de datos a partir de fuentes heterogéneas.

El término hace referencia a tres operaciones encadenadas. La extracción consiste en acceder a las fuentes de información originales y obtener los datos en bruto que estas contienen, tal y como fueron generados por los sistemas de origen. La transformación abarca todas las operaciones necesarias para limpiar, normalizar, reestructurar y enriquecer esa información, adaptándola a los requisitos del análisis que se quiere realizar. Finalmente, la carga hace referencia a la consolidación del resultado en un único conjunto de datos estructurado y coherente, listo para ser utilizado en las fases posteriores. En este trabajo, el resultado final de este proceso es el *dataset* analítico sobre el que se aplicarán los modelos de clasificación supervisada.

Un aspecto fundamental que condiciona el desarrollo de esta fase es la naturaleza de los datos en bruto obtenidos tras la extracción. Estos datos, denominados habitualmente *raw dataset*, pueden requerir una revisión para su uso en el ámbito del análisis y modelado, lo que los hace inadecuados para su uso directo en procesos de análisis o modelado. Los problemas más habituales en este tipo de conjuntos incluyen valores ausentes, registros duplicados, tipos de dato inconsistentes, campos con contenido ambiguo o variables con una cobertura insuficiente para resultar útiles en el modelo final.

En un proceso ETL no existe una única forma correcta de resolver incidencias como valores ausentes, inconsistencias o errores de codificación. La elección del tratamiento adecuado depende del contexto, de la calidad de los datos y de los objetivos del análisis. Se requiere evaluar cada situación de forma independiente en función de la naturaleza de la variable afectada y del impacto potencial sobre el análisis. En términos generales, las estrategias disponibles pueden agruparse en tres grandes aproximaciones. La primera consiste en el descarte de registros o variables, eliminando aquellos elementos que presenten errores, valores ausentes mayoritarios o escasa relevancia para el problema planteado. Aunque es la opción más sencilla de aplicar, puede introducir sesgos si la información eliminada no es verdaderamente irrelevante. La segunda estrategia es la imputación de valores, que consiste en sustituir los valores ausentes o erróneos por estimaciones calculadas a partir del resto de la información disponible, utilizando medidas estadísticas como la media, la mediana o la moda según la distribución de cada variable. Existen además métodos de imputación más avanzados,

basados en modelos de regresión o árboles de decisión, capaces de estimar valores a partir de patrones presentes en el conjunto de datos. La tercera aproximación consiste en la transformación de variables, especialmente necesaria cuando se trabaja con datos cualitativos que deben ser convertidos a representaciones numéricas para poder ser utilizados en algoritmos de aprendizaje automático.

Un elemento especialmente relevante dentro del proceso ETL de este trabajo fue la transición entre formatos de fichero. Las fuentes iniciales de trabajo fueron ficheros en formato *dbf* que fueron reemplazadas, tras la rectificación por parte de los investigadores del INIA-CSIC, por ficheros en formato ESRI *shapefile*. Este formato consta de varios ficheros, es uno de los formatos GIS vectoriales más usados. A diferencia del formato *dbf*, que únicamente contiene información tabular sobre los atributos de cada elemento, el *shapefile* integra simultáneamente la información geométrica (la forma y posición espacial de cada entidad) con sus atributos descriptivos. Esta capacidad de representar tanto el qué como el dónde de cada registro convierte al formato *shp* en el soporte adecuado para trabajar con información geoespacial, siendo imprescindible para poder realizar posteriormente las operaciones de integración espacial entre ficheros [27], [28].

A partir de este punto, el proceso ETL se desarrolló de forma individualizada sobre cada uno de los cinco ficheros que componen el conjunto definitivo de fuentes. Para cada uno de ellos se evaluaron las variables disponibles, se tomaron decisiones sobre qué atributos resultaban relevantes para el análisis y se descartaron aquellos que presentaban problemas de cobertura, contenido no estructurable o naturaleza puramente administrativa. El resultado de este proceso, fichero a fichero, sentó las bases para la construcción del *dataset* integrado que se describe en el apartado siguiente.

4.4. Preparación de datos.

Una vez establecido el marco general del proceso ETL y completada la transición hacia los ficheros en formato *shapefile* proporcionados por el INIA-CSIC, el siguiente paso consiste en analizar de forma individualizada cada una de las cinco fuentes que componen el conjunto definitivo de datos. Para cada fichero se evaluaron las variables disponibles, se identificaron aquellas con capacidad real de aportar información útil al modelo de clasificación y se descartaron los atributos que presentaban problemas de cobertura, contenido no estructurable o naturaleza puramente administrativa. Las decisiones adoptadas en esta fase son determinantes para la calidad del *dataset* final, ya que una selección incorrecta de variables puede introducir ruido en el modelo o reducir su capacidad predictiva.

- FICHERO 1: brotes1.xlsx.

Entre sus variables principales destacan *country* y *region*, que identifican el país y la región geográfica del brote; *Reporting_date*, que recoge la fecha de notificación; *wild_type*, que indica

si el animal afectado es silvestre, doméstico, en cautividad o asilvestrado; *Species* y *Orden*, que clasifican taxonómicamente el animal afectado a nivel de especie y orden respectivamente; y *Ave_mm*, que distingue entre aves y mamíferos.

Las variables *Longitude* y *Latitude* adquieren especial relevancia en este contexto, ya que constituyen el elemento de enlace entre este fichero y el resto de fuentes geográficas. Son las que hacen posible realizar las operaciones de integración espacial descritas en el apartado siguiente. Por su parte, la variable *Orden* adquiere una importancia particular en la fase de aprendizaje automático, donde (tras un proceso de agrupación en ocho clases que se detalla en el apartado correspondiente) se convierte en la variable objetivo del modelo de clasificación.

■ FICHERO 2 : sites

Este fichero aporta información sobre Áreas Importantes para las Aves (IBA) y Áreas Clave para la Biodiversidad (KBA) a escala mundial, proporcionado por BirdLife International. Contiene 14.011 áreas geográficas catalogadas con su geometría asociada, lo que permite determinar si la localización de un brote cae dentro de alguna de estas áreas protegidas.

Las variables incorporadas al *dataset* final fueron *SitRecID*, identificador único del área; *IbaStatus* y *KbaStatus*, que indican el estado de clasificación del área como IBA o KBA respectivamente; *KbaClass*, que especifica el tipo de KBA; y *SitAreaKm2*, que recoge la superficie del área en kilómetros cuadrados. Estas variables fueron seleccionadas por su capacidad para caracterizar geográficamente cada brote en relación con las áreas de protección de biodiversidad, siendo potencialmente relevantes como elementos de predicción en el modelo. El resto de variables fueron descartadas atendiendo a tres criterios: variables con un elevado porcentaje de valores ausentes (como *AzeStatus*, presente en menos del 4 % de los registros), variables de texto libre no estructurable como *DelTxt*, y variables de naturaleza puramente administrativa como *Source*, *SitSource* o *LastUpdate*, que recogen metadatos sobre el origen y actualización del dato sin aportar información relevante sobre las características geográficas o ecológicas del área.

■ FICHERO 3 : features_centroid_publishedPoint

Este fichero proporcionó una variable a incluir en el *dataset* final que solventó el problema planteado por la propia información contenida. El valor de la variable *dist_ramsar_km* para recoger la distancia en kilómetros de cada brote respecto al humedal Ramsar más cercano. El resto, quedaron como metadatos de referencia.

Su tratamiento dentro del proceso ETL presentó una particularidad relevante que condicionó la forma en que su información fue incorporada al *dataset*: a diferencia de los ficheros de polígonos, este fichero contiene geometrías de puntos que representan el centroide publicado de cada humedal, no su contorno real.

- FICHERO 4 : riquezaespecies

Este fichero contiene un índice de riqueza de especies organizado en una cuadrícula de 10x10 km por celda. Sin embargo, su cobertura geográfica es exclusivamente española, lo que introdujo una limitación importante al cruzarlo con el *dataset* global de 54.308 brotes mundiales. El resultado fue el siguiente:

Tabla 2. Rango de coordenadas del fichero 4

Estadístico	Longitud	Latitud
Mínimo	-18.2°	27.7°
Máximo	+4.3°	43.8°

El rango de coordenadas mostrada en la tabla 2, se encuentra íntegramente dentro del ámbito geográfico de la Península Ibérica, incluyendo el territorio español (Península, Islas Baleares e Islas Canarias), sin registros fuera de dicho ámbito. Como consecuencia, al cruzar esta capa con el *dataset* global se obtuvieron 53.421 valores ausentes, equivalentes al 98 % de los registros sin valor asignado. Incluir una variable con ese nivel de ausencia en un modelo global introduciría más ruido que información útil, por lo que fue descartada del *dataset* principal. Este descarte fue reconvertido es un *dataset* solo la información de los registros españoles. Un total de 882 registros que sí dispone de cobertura completa para esta variable, lo que la convierte en un elemento de predicción potencialmente valioso para la fase de aplicación regional sobre España.

Por qué se conserva para España.

El subconjunto español de 882 registros sí tiene cobertura completa de esta variable, lo que la convierte en un elemento de predicción potencialmente muy valioso para la fase 2 del TFG (cuando se aplique el modelo entrenado globalmente sobre los datos españoles, enriquecidos además con *RIQUEZAESP* variable que recoge el índice de riqueza de especies por celda de 10x10km disponible exclusivamente para España).

- FICHERO 5 : IBAs_criteria_included

Este fichero, incorporado por el INIA-CSIC en la segunda entrega de fuentes, es un subconjunto de *sites.shp* tal y como se indicó en el apartado de *Rectificación de fuentes*. El solapamiento existente entre *sites.shp* y *IBAs_criteria_included.shp* queda reflejado en la tabla 3:

Tabla 3. Comparación de cobertura entre ambos ficheros

Fichero	Cobertura	Registros
Fichero 2	Mundial	14.011
Fichero 5	Solo América	1.001

Los 1.001 registros americanos del fichero *IBAs_criteria_included.shp* están ya contenidos dentro de los 14.011 del fichero *sites.shp*, por lo que utilizar ambos habría supuesto duplicar información para el continente americano. Por este motivo fue descartado del *dataset* final. No obstante, este fichero aportaba columnas adicionales no presentes en el fichero *sites.shp* (*IbaClassif*, *KbaClassif*, *IbaCriteri*, *KbaCriteri* e *YearOfLast*) con información más detallada sobre la clasificación de cada área. Se valoraron dos opciones: usar exclusivamente el fichero *sites.shp* mundial, más limpio y sin duplicados; o enriquecer el fichero *sites.shp* con las columnas adicionales del fichero *IBAs_criteria_included.shp* mediante una operación de merge por identificador común. Se optó por la primera alternativa por ser más adecuada para el tratamiento posterior en aprendizaje automático, aunque la segunda opción queda señalada como posible ampliación de futuros análisis.

Una vez completado el análisis y la selección de variables por fichero, el paso siguiente consiste en establecer cómo se relacionan entre sí las distintas fuentes para construir el *dataset* integrado final. Esta fase representa el momento en que los ficheros dejan de ser conjuntos de datos independientes para convertirse en partes de un único entorno analítico coherente, donde cada registro de brote queda enriquecido con el contexto geográfico y ecológico que por sí solo no contiene.

La figura 2 resume gráficamente el proceso de integración, mostrando el papel que desempeña cada fichero y el tipo de relación que se establece entre ellos.

El punto de partida es el fichero 1, el único que contiene registros de brotes de gripe aviar, y el objetivo es enriquecerlo con la información georreferenciada que aportan los cuatro conjuntos de datos en formato ESRI *Shapefile* restantes. El elemento común que hace posible esta integración son las coordenadas geográficas: el fichero 1 dispone de las variables *Longitude* y *Latitude* de cada brote, mientras que los ficheros *Shapefile* contienen geometrías (polígonos o puntos) que representan áreas geográficas concretas.




Figura 2. Proceso de Integración. Fuente: Elaboración propia.

La técnica utilizada para cruzar esta información es la unión espacial o *sjoin*, que a diferencia de un *join* tradicional (que busca coincidencias entre identificadores comunes) busca coincidencias geométricas: determina si un punto cae dentro de un polígono, o calcula la distancia a la entidad geográfica más cercana cuando el cruce directo no es posible.

Los ficheros 2 y 3 participan activamente en el *dataset* global. El fichero 2, que contiene las áreas IBA/KBA a escala mundial, aporta variables de clasificación de áreas protegidas para cada brote mediante un cruce por contención geométrica. El fichero 3, que recoge los humedales Ramsar como puntos geográficos, contribuye con la variable *dist_ramsar_km* (la distancia en kilómetros al humedal más cercano para cada brote) al no disponer de geometría poligonal que permitiera un cruce directo.

El fichero 4, con cobertura geográfica exclusivamente española, generó un 98% de valores ausentes al cruzarlo con el *dataset* global, por lo que fue descartado del modelo principal aunque se conserva para la fase de aplicación regional sobre España. El fichero 5 fue analizado durante el proceso de integración y depuración de datos correspondiente a la fase ETL, observándose que la información que contenía ya se encontraba representada en otros conjuntos de datos incorporados al estudio. Dado que no aportaba variables adicionales de interés y con el objetivo de evitar redundancias en la construcción del *dataset* analítico, se decidió excluirlo del proceso de integración. Sus columnas

adicionales quedaron documentadas para su posible utilización en futuras investigaciones o desarrollos del modelo.

4.5. Análisis del *dataset*.

El resultado de todo el proceso anterior de integración es un *dataset* enriquecido de 53.370 registros y 16 variables, cuya relación se recoge en la tabla 4. Este *dataset* incluye además un subconjunto de 882 registros correspondientes a España, que será utilizado en la fase de aplicación regional del modelo de aprendizaje automático. La descripción detallada de cada variable se recoge en el Anexo C.

Tabla 4. Variables del *dataset* enriquecido

Variable	Tipo
country	Texto
region	Texto
Reporting_date	Fecha
Longitude	Numérico
Latitude	Numérico
wild_type	Texto
Species	Texto
Ave_mm	Texto
Orden	Texto
geometry	Geometría
SitReclD	Numérico
IbaStatus	Texto
KbaStatus	Texto
KbaClass	Texto
SitAreaKm2	Numérico
dist_ramsar_km	Numérico

Una de las preguntas que motivaron el planteamiento de este TFG es si existe una relación estadísticamente observable entre la distribución geográfica de los brotes de gripe aviar en aves y la distribución de los casos registrados en mamíferos. Para explorar esta posible relación antes de aplicar los modelos de clasificación, se recurrió al análisis de correlación entre las distribuciones espaciales de

los brotes de ambos grupos, utilizando dos coeficientes estadísticos complementarios: el coeficiente de correlación de Pearson y el coeficiente de correlación de Spearman.

Dado que los registros de brotes son puntos geográficos dispersos y no variables continuas directamente comparables, el análisis requirió un paso previo de estimación de densidad espacial. Para ello se utilizó la técnica *Kernel Density Estimation* (KDE), implementada mediante la función *gaussian_kde* de la librería *SciPy* con un ancho de banda (parámetro *bw_method*) fijado en 0,3. Esta técnica transforma una distribución discreta de puntos en una superficie continua de densidad, estimando la concentración de eventos sobre una malla regular de 300×150 puntos que cubre la totalidad del rango geográfico de longitud (-180° a 180°) y latitud (-90° a 90°). El resultado son dos matrices bidimensionales (una para aves y otra para mamíferos) que representan la densidad relativa de brotes en cada zona. Estas matrices se aplanan para obtener dos vectores comparables sobre los que se calculan los coeficientes de correlación.

■ Correlación de Pearson.

El coeficiente de correlación de Pearson permite cuantificar el grado de relación lineal entre dos variables cuantitativas, proporcionando una medida normalizada de asociación en el rango $[-1, 1]$, donde 1 indica correlación directa, -1 correlación inversa y 0 ausencia de relación lineal.

Cálculo de la correlación de Pearson entre densidades KDE.

Dados dos vectores aplanados procedentes de las matrices de densidad KDE:

$$X = \{x_1, x_2, \dots, x_n\}, \quad Y = \{y_1, y_2, \dots, y_n\}$$

donde cada par (x_i, y_i) corresponde a un píxel de las matrices de densidad, el coeficiente de Pearson se define como:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{(\sum_{i=1}^n (x_i - \bar{x})^2) (\sum_{i=1}^n (y_i - \bar{y})^2)}}$$

donde:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$$

■ Correlación de Spearman.

Como complemento al análisis anterior, se utiliza el coeficiente de correlación de Spearman con el objetivo de evaluar la consistencia de los resultados bajo un enfoque no paramétrico. A diferencia de Pearson, que mide la relación lineal entre los valores originales, Spearman cuantifica el grado de relación monótona entre dos variables basándose en los rangos de los datos. Esto lo convierte en una medida más robusta frente a la presencia de valores atípicos y frente a relaciones que, siendo consistentes, no siguen un patrón estrictamente lineal.

Dado que se trabaja sobre las mismas matrices de densidad KDE aplanadas, se asigna a cada valor su rango dentro del vector correspondiente. El coeficiente de Spearman se define como:

Cálculo de la correlación de Spearman entre densidades KDE.

$$\rho = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)}$$

donde d_i es la diferencia entre los rangos asignados a cada par de observaciones (x_i, y_i) .

La utilización conjunta de ambos coeficientes no es redundante sino complementaria. Pearson captura la intensidad de la relación lineal entre las densidades, mientras que Spearman verifica si esa relación se mantiene de forma consistente independientemente de la distribución de los datos. La concordancia entre ambos resultados refuerza la solidez de las conclusiones obtenidas, mientras que una divergencia significativa entre ellos indicaría la presencia de no linealidades o valores extremos que condicionan el análisis. Los valores concretos obtenidos y su interpretación se desarrollan en el apartado de resultados.

4.6. Introducción a la fase de *Machine Learning*.

Una vez completado el análisis del *dataset* descrito en el apartado anterior, el siguiente paso natural dentro del proceso de minería de datos es la construcción de modelos de aprendizaje automático que permitan extraer patrones predictivos a partir de la información recopilada y procesada.

El aprendizaje automático o *Machine Learning* engloba un amplio conjunto de técnicas y algoritmos cuyo objetivo es aprender patrones a partir de datos sin ser programados explícitamente para ello. En el contexto de este trabajo, el problema a resolver es de clasificación multiclase; dado un conjunto de variables geográficas y taxonómicas asociadas a un brote, predecir a qué orden taxonómico pertenece el animal afectado. Entre los modelos de clasificación más utilizados en la literatura se encuentran,

entre otros, la Regresión Logística, los Árboles de Decisión, el *Random Forest*, el *Gradient Boosting*, las Redes Neuronales y las Máquinas de Vectores de Soporte (SVM). De entre estos modelos, en este trabajo se seleccionan *Random Forest*, como modelo principal, y Regresión Logística, como modelo de contraste, cuya elección se justifica en los apartados siguientes.

4.6.1. Definición ampliada de conceptos utilizados.

En este apartado se presentan los conceptos técnicos necesarios para contextualizar el proceso de modelado, evaluación y preparación de datos aplicado en el análisis epidemiológico desarrollado en este trabajo. Su definición permite comprender las operaciones realizadas en las fases posteriores del flujo ETL y del modelado predictivo.

- **Algoritmos de modelado supervisado.**

- **Random Forest**

Random Forest es un algoritmo de aprendizaje automático supervisado basado en la combinación de múltiples árboles de decisión. Su funcionamiento se fundamenta en la construcción de numerosos árboles entrenados sobre subconjuntos aleatorios del *dataset* y de las variables disponibles, combinando posteriormente sus predicciones mediante mecanismos de votación o promediado. Esta estrategia reduce el riesgo de sobreajuste característico de los árboles individuales y mejora la capacidad de generalización del modelo.

Una de las principales ventajas de *Random Forest* es su capacidad para trabajar con *datasets* complejos y heterogéneos, manejando simultáneamente variables numéricas y categóricas sin requerir grandes transformaciones previas. Además, el algoritmo resulta especialmente robusto frente a ruido, valores ausentes y relaciones no lineales entre variables.

En el contexto de la minería de datos epidemiológica, *Random Forest* se utiliza frecuentemente para tareas de clasificación y predicción de riesgo, ya que permite identificar patrones complejos difíciles de detectar mediante técnicas estadísticas tradicionales. Otra característica relevante es la posibilidad de estimar la importancia relativa de cada variable dentro del modelo, proporcionando información útil para interpretar qué factores influyen más en la predicción final.

- **Regresión logística**

La regresión logística es un modelo estadístico supervisado utilizado principalmente en problemas de clasificación. A diferencia de la regresión lineal, cuyo objetivo es predecir valores continuos, la regresión logística estima la probabilidad de pertenencia de una observación a una determinada clase mediante una función logística o sigmoide.

El modelo transforma una combinación lineal de variables independientes en una probabilidad comprendida entre 0 y 1, permitiendo establecer criterios de clasificación binaria o multiclase. Su formulación matemática facilita además la interpretación estadística de los coeficientes asociados a cada variable, lo que convierte a este modelo en una herramienta especialmente útil cuando la interpretabilidad resulta importante.

En proyectos de minería de datos y epidemiología computacional, la regresión logística se emplea habitualmente como modelo base de comparación debido a su simplicidad, rapidez de entrenamiento y capacidad para ofrecer resultados fácilmente interpretables. Aunque su capacidad predictiva puede verse limitada frente a algoritmos más complejos, continúa siendo una referencia ampliamente utilizada en problemas de clasificación supervisada.

■ Problemas comunes en el aprendizaje automático.

■ **Overfitting**

El *overfitting* o sobreajuste es un problema habitual en aprendizaje automático que ocurre cuando un modelo aprende excesivamente los detalles y el ruido presentes en los datos de entrenamiento, perdiendo capacidad para generalizar correctamente sobre datos nuevos no vistos durante el entrenamiento.

Un modelo sobreajustado puede alcanzar resultados aparentemente excelentes durante la fase de entrenamiento, pero degradar significativamente su rendimiento cuando se aplica sobre conjuntos de validación o datos reales. Este comportamiento suele aparecer cuando el modelo posee demasiada complejidad respecto a la cantidad o calidad de los datos disponibles.

Entre las causas más frecuentes de *overfitting* se encuentran el uso de modelos excesivamente complejos, *datasets* pequeños, presencia de ruido o un número elevado de variables irrelevantes. Para reducir este problema se emplean técnicas como validación cruzada, regularización, reducción de dimensionalidad o selección de variables.

En minería de datos aplicada a epidemiología, el control del sobreajuste resulta especialmente importante debido a la naturaleza dinámica y heterogénea de los sistemas epidemiológicos,

donde los patrones observados pueden cambiar con el tiempo y entre regiones geográficas.

- **Desbalanceo de clases**

El desbalanceo de clases es un problema habitual en aprendizaje automático que aparece cuando una o varias clases presentan un número muy reducido de ejemplos respecto al resto, situación frecuente en problemas epidemiológicos y de detección de eventos raros.

Los modelos entrenados sobre *datasets* desbalanceados tienden a favorecer las clases mayoritarias, pudiendo obtener tasas de acierto elevadas (*accuracy*) mientras clasifican incorrectamente la mayoría de los casos minoritarios. Para corregir este desequilibrio se aplican diferentes estrategias de balanceo de clases.

Entre las técnicas más habituales se encuentran el *undersampling*, que reduce el número de ejemplos de las clases mayoritarias; el *oversampling*, que incrementa artificialmente las clases minoritarias; y métodos más avanzados como *SMOTE*, capaces de generar ejemplos sintéticos a partir de patrones existentes.

El balanceo de clases resulta especialmente importante en sistemas de vigilancia epidemiológica, donde los brotes o eventos críticos suelen representar únicamente una pequeña proporción del total de registros disponibles.

- **Técnicas de evaluación del modelo.**

- **Validación cruzada**

La validación cruzada es una técnica de evaluación utilizada en aprendizaje automático para estimar la capacidad de generalización de un modelo predictivo. Su objetivo consiste en comprobar cómo se comporta el modelo cuando se aplica sobre datos no utilizados durante el entrenamiento.

El procedimiento más habitual es la validación cruzada k-fold, donde el *dataset* se divide en k subconjuntos o particiones. En cada iteración, uno de los subconjuntos se utiliza como conjunto de validación mientras el resto se emplea para entrenar el modelo. El proceso se repite sucesivamente hasta que todas las particiones han sido utilizadas como validación al menos una vez.

Esta metodología permite obtener estimaciones de rendimiento más robustas que una única división *train-test*, reduciendo la dependencia respecto a una partición concreta

de los datos. Además, ayuda a detectar problemas de sobreajuste y proporciona una evaluación más estable de la capacidad predictiva del modelo.

La validación cruzada resulta especialmente útil en contextos donde el número de registros disponibles es limitado o donde la distribución de clases presenta desequilibrios importantes.

- **AUC-ROC**

El AUC-ROC (*Area Under the Curve - Receiver Operating Characteristic*) es una métrica utilizada para evaluar el rendimiento de modelos de clasificación binaria. La curva ROC representa la relación entre la tasa de verdaderos positivos y la tasa de falsos positivos para distintos umbrales de decisión del modelo.

El valor AUC corresponde al área bajo dicha curva y proporciona una medida global de la capacidad discriminativa del modelo. Valores cercanos a 1 indican una excelente capacidad de clasificación, mientras que valores próximos a 0.5 sugieren un comportamiento equivalente al azar.

Una de las principales ventajas del AUC-ROC es que permite evaluar modelos independientemente del umbral de clasificación seleccionado, proporcionando una visión más general del rendimiento predictivo. Además, resulta especialmente útil en problemas donde las clases presentan desequilibrios importantes.

En aplicaciones epidemiológicas, esta métrica se emplea frecuentemente para evaluar modelos de detección de riesgo, vigilancia de enfermedades o clasificación de brotes, donde resulta importante minimizar tanto falsos positivos como falsos negativos.

- **F1-score**

El *F1-score* es una métrica de evaluación utilizada en problemas de clasificación supervisada que combina precisión (*precision*) y exhaustividad (*recall*) en una única medida. Se calcula como la media armónica entre ambas métricas, proporcionando un equilibrio entre la capacidad del modelo para detectar correctamente los casos positivos y evitar clasificaciones erróneas.

Su formulación penaliza especialmente los modelos que obtienen buenos resultados en una métrica pero pobres en la otra, convirtiéndolo en un indicador más equilibrado que la simple exactitud global (*accuracy*).

El *F1-score* resulta especialmente relevante en *datasets* desbalanceados, donde una de las clases presenta muchos más registros que las demás. En estos casos, la *accuracy*

puede ofrecer resultados engañosos, mientras que el *F1-score* proporciona una evaluación más representativa del comportamiento real del modelo.

En problemas epidemiológicos, donde los eventos positivos pueden ser relativamente infrecuentes, esta métrica adquiere especial importancia para evaluar correctamente la capacidad de detección de casos relevantes.

- **Preparación y transformación de variables.**

- **Feature engineering**

El *feature engineering* o ingeniería de características es el proceso de creación, transformación y selección de variables con el objetivo de mejorar el rendimiento de los modelos de aprendizaje automático. Constituye una de las fases más importantes dentro de cualquier proyecto de minería de datos, ya que la calidad y representatividad de las variables influyen directamente sobre la capacidad predictiva del modelo.

Este proceso incluye tareas como transformación de variables categóricas a representaciones numéricas, creación de nuevas variables derivadas, normalización de escalas, agrupación de categorías o eliminación de atributos redundantes. En muchos casos, el *feature engineering* permite capturar relaciones complejas que no están explícitamente representadas en los datos originales.

En análisis epidemiológico y geoespacial, la ingeniería de características suele incorporar además variables derivadas del entorno territorial, distancias geográficas, densidades espaciales o indicadores ambientales contruidos a partir de múltiples fuentes de información.

La literatura especializada considera habitualmente que un buen proceso de *feature engineering* puede tener un impacto sobre el rendimiento del modelo comparable o incluso superior al de la elección del algoritmo utilizado.

- **Conceptos de análisis espacial.**

- **KDE**

Es una herramienta de análisis espacial que convierte un conjunto de observaciones puntuales en una representación continua del territorio. Su objetivo es reflejar la intensidad relativa de los eventos en diferentes áreas, proporcionando una visión global de su distribución y permitiendo estudiar tendencias espaciales que no son evidentes a partir de los puntos individuales.

En epidemiología espacial, KDE se emplea frecuentemente para analizar distribuciones geográficas de brotes, identificar zonas de alta concentración y estudiar patrones de propagación territorial de enfermedades.

Una de las ventajas principales de KDE frente a métodos basados en histogramas es que genera representaciones más suaves y menos dependientes de divisiones arbitrarias del espacio geográfico, permitiendo detectar patrones espaciales de forma más estable y visualmente interpretable.

4.6.2. Modelo principal: *Random Forest*.

Para este trabajo se ha seleccionado *Random Forest* como modelo principal de clasificación. *Random Forest* es un método de aprendizaje en conjunto (*ensemble learning*) basado en la construcción de múltiples árboles de decisión durante el entrenamiento, combinando sus predicciones mediante votación mayoritaria para obtener un resultado final más robusto y generalizable que el de cualquier árbol individual.

Las razones que justifican esta elección son las siguientes:

- **Robustez ante el desbalance de clases:** El *dataset* presenta un desbalance significativo, con Galliformes representando aproximadamente el 50 % de los registros. *Random Forest* permite ajustar el parámetro *class_weight* para compensar este desequilibrio sin necesidad de técnicas adicionales de remuestreo.
- **Capacidad para manejar variables mixtas:** El *dataset* combina variables numéricas (*Longitude*, *Latitude*, *dist_ramsar_km*, *SitAreaKm2*) y variables categóricas codificadas, lo que *Random Forest* gestiona de forma natural.
- **Resistencia al *overfitting*:** A diferencia de un árbol de decisión individual, que puede presentar una elevada tendencia al sobreajuste, *Random Forest* reduce este riesgo mediante la construcción de múltiples árboles entrenados sobre muestras aleatorias de los datos y subconjuntos aleatorios de variables. La agregación de las predicciones de todos los árboles disminuye la varianza del modelo y mejora su capacidad de generalización sobre datos no vistos.
- **Interpretabilidad de las variables:** *Random Forest* proporciona una medida de importancia de cada variable en la predicción (*feature importance*), lo que permite identificar qué factores geográficos y taxonómicos son más relevantes para el modelo (un resultado de especial interés para los objetivos de este estudio).

- **Solidez académica:** Es uno de los algoritmos más citados y utilizados en la literatura científica de minería de datos, con amplia documentación y soporte en la librería *scikit-learn* de Python.

4.6.3. Modelo de contraste: Regresión Logística.

Para evaluar objetivamente el rendimiento de *Random Forest*, se ha seleccionado la Regresión Logística como modelo de contraste o *baseline*. Aunque su nombre puede inducir a confusión, la Regresión Logística es un modelo de clasificación (no de regresión) ampliamente utilizado como punto de referencia en problemas de clasificación multiclase.

Su elección como modelo de contraste se justifica por las siguientes razones:

- **Simplicidad y transparencia:** es un modelo lineal cuyo funcionamiento es fácilmente explicable e interpretable, lo que facilita la comparación con modelos más complejos.
- **Uso académico consolidado:** es el modelo de referencia (*baseline*) más utilizado en la literatura científica para problemas de clasificación, lo que otorga solidez metodológica a la comparativa.
- **Rapidez de entrenamiento:** su bajo coste computacional permite obtener resultados de referencia de forma rápida, sin necesidad de ajuste de hiperparámetros complejo.
- **Capacidad de contraste:** si *Random Forest* mejora significativamente los resultados de la Regresión Logística, queda demostrado que la complejidad adicional del modelo *ensemble* está justificada. Si la mejora es marginal, el modelo más simple sería preferible por el principio de parsimonia.

En este trabajo, la Regresión Logística se emplea como modelo base de comparación por tratarse de un algoritmo ampliamente estudiado y validado, cuyo rendimiento en tareas de clasificación está sobradamente documentado. Su utilización permite valorar con rigor si el incremento de complejidad asociado a *Random Forest* se traduce en una mejora predictiva real y estadísticamente justificada.

4.6.4. Aplicación del modelo *Random Forest* sobre el contexto español.

Una vez entrenado y evaluado el modelo de *Random Forest* a escala global, se diseñó una fase de validación geográfica consistente en aplicar dicho modelo, sin reentrenamiento, sobre el subconjunto de registros correspondientes a España. El objetivo de esta fase es analizar hasta qué

punto los patrones aprendidos a partir de datos mundiales mantienen su capacidad predictiva cuando se trasladan a un contexto geográfico más específico.

Esta decisión metodológica es relevante porque permite distinguir entre dos escenarios distintos: entrenar un modelo exclusivamente con datos españoles, lo que limitaría su generalización, o aplicar un modelo de alcance global a un subconjunto regional, evaluando así su transferibilidad. Este trabajo adopta el segundo enfoque, por ser coherente con el objetivo declarado de desarrollar un sistema de predicción de aplicabilidad global.

Para garantizar la coherencia con la codificación del modelo global, el subconjunto español requirió un proceso de preparación específico, que incluyó la normalización de valores categóricos y la resolución de inconsistencias detectadas en las variables *wild_type*, *Ave_mm*, *IbaStatus*, *KbaStatus* y *KbaClass*, mediante mapeos explícitos compatibles con los *encoders* entrenados sobre el *dataset* global.

Para la evaluación del modelo sobre este subconjunto se consideraron únicamente las clases taxonómicas presentes en los registros españoles. Las clases *Artiodactyla* y *Carnivora*, aunque conocidas por el modelo global, no cuentan con registros en el conjunto de datos español y fueron por tanto excluidas de las métricas y representaciones gráficas. Esta exclusión no constituye una limitación del modelo, sino una consecuencia directa de la distribución real de los brotes registrados en España durante el período analizado.

5. Resultados.

Este apartado presenta los resultados obtenidos a partir de la aplicación de la metodología propuesta. La práctica totalidad de estos resultados se derivan del *dataset* resultante del proceso de integración de los ficheros de origen, descrito en el apartado 4.4 y representado en la figura 3 (Proceso de Integración), sobre el cual se han aplicado las técnicas de minería de datos y análisis espacial expuestas en el primer bloque de este capítulo. Sobre este mismo *dataset* se aplican también los modelos de *Machine Learning* desarrollados, cuya evaluación se complementa, en la aplicación regional sobre España, con la incorporación de la variable de riqueza de especies (fichero 4), descartada del *dataset* global por su elevado porcentaje de valores ausentes pero disponible con cobertura completa para el subconjunto español.

5.1. Minería de datos

En los apartados siguientes se presentan los gráficos generados, seleccionados en función de su relevancia para los objetivos de este TFG. La caracterización detallada de los ficheros de origen (campos, variables seleccionadas y criterios de descarte) se recoge en el Anexo B, al que se remite al lector para una consulta exhaustiva de las fuentes utilizadas. La mayor parte de los gráficos representan datos acumulados correspondientes al periodo 2004-2025. Cuando ha sido posible, se ha priorizado una interpretación de carácter cuantitativo, propia de la minería de datos, si bien se incorporan también observaciones de naturaleza epidemiológica que contextualizan los resultados obtenidos.

5.1.1. Orden Taxonómico

Para la representación de las agrupaciones de datos según la tipología recogida en las fuentes se ha optado por una gráfica de barras, que permite visualizar con claridad la distribución del número de brotes registrados por cada orden taxonómico presente en el *dataset*. Esta representación facilita identificar tanto los órdenes con mayor número de registros como aquellos con una presencia más reducida, proporcionando una primera aproximación a la composición taxonómica del conjunto de datos sobre el que se trabaja en las fases posteriores del estudio.




Figura 3. Distribución de brotes por orden taxonómico. Fuente: Elaboración propia.

■ **Discusión de Resultados:**

La figura 3 muestra un claro predominio del orden Galliformes, que concentra 26.801 registros, más del doble que Anseriformes y más de cinco veces los observados en Charadriiformes. Esta distribución no parece responder únicamente a diferencias biológicas en la susceptibilidad al virus, sino también al propio contexto de vigilancia epidemiológica en el que se generan los datos. En conjunto, la elevada representación de Galliformes (explicable, como se ha señalado, por la intensa vigilancia sanitaria sobre explotaciones avícolas más que por una mayor susceptibilidad biológica al virus) sugiere que la distribución observada refleja simultáneamente la dinámica epidemiológica real de la enfermedad y los sesgos inherentes a los sistemas de vigilancia y notificación en los que se basa el *dataset*. Esta limitación debe tenerse presente en la interpretación de los resultados posteriores. Como consecuencia, el *dataset* presenta una representación especialmente elevada de este grupo, generando además un importante desequilibrio taxonómico que debe ser considerado durante las fases posteriores de modelado.

La categoría Otros agrupa 15 órdenes taxonómicos cuya representación individual no superaba el umbral mínimo establecido para constituir una clase independiente en el modelo, sumando en conjunto 4.280 registros. De estos órdenes, 14 corresponden a aves (entre ellos Suliformes, Passeriformes, Pelecaniformes o Falconiformes, entre otros) y uno a mamíferos (Rodentia, con 15 registros). Desde una perspectiva global, el *dataset* presenta un marcado predominio de registros correspondientes a aves, con 51.391 casos frente a los 1.979 registros de mamíferos

(que incluyen Artiodactyla, Carnivora y los 15 registros de Rodentia agrupados en Otros), lo que supone que los mamíferos representan en torno al 3,7 % del total de registros disponibles. Aun así, la presencia de un número considerable de registros pertenecientes a Anseriformes y Charadriiformes mantiene un interés epidemiológico notable, ya que ambos órdenes agrupan numerosas especies de aves acuáticas silvestres reconocidas como reservorios naturales del virus y estrechamente vinculadas a su dispersión a través de rutas migratorias. En contraste, los órdenes correspondientes a mamíferos presentes en el *dataset*; Carnivora (que agrupa, entre otros, a cánidos y mustélidos como zorros y visones) y Artiodactyla (que agrupa, entre otros, a cérvidos y suidos como ciervos y jabalíes), presentan una frecuencia mucho menor, lo que resulta coherente con la menor incidencia observada de infecciones en estos grupos y con las dificultades inherentes a la vigilancia sistemática de fauna silvestre.

5.1.2. Orden Huéspedes

Para representar la distribución de los brotes según el tipo de hospedador en el que se registró cada caso, se ha empleado una gráfica de barras correspondiente a la variable *wild_type*, que clasifica los registros del *dataset* en cuatro categorías: doméstico, silvestre, en cautividad (*Captive*, animales en zoológicos o centros de rescate) y asilvestrado de origen doméstico (*Feral*). Esta representación permite comparar de forma directa el peso relativo de cada categoría dentro del conjunto de datos, anticipando si la información disponible se concentra mayoritariamente en un único entorno (doméstico o silvestre) o si, por el contrario, recoge de forma equilibrada eventos procedentes de ambos. Esta distinción resulta especialmente relevante para comprender el alcance de la vigilancia epidemiológica reflejada en los datos y su posterior tratamiento en la fase de modelado.

■ **Discusión de Resultados:**

La muestra una distribución notablemente equilibrada de los brotes entre animales domésticos (51,7 %) y animales silvestres (46,3 %). A diferencia de lo observado en la distribución taxonómica, donde determinados grupos concentraban una proporción muy elevada de registros, en este caso ninguna categoría domina claramente el conjunto de datos. Esta situación resulta especialmente relevante, ya que indica que la información disponible recoge de forma significativa eventos registrados tanto en entornos productivos como en poblaciones silvestres, proporcionando una visión más amplia de la circulación del virus.

La elevada representación de animales domésticos es coherente con la intensa vigilancia sanitaria existente sobre explotaciones avícolas, donde los brotes generan importantes consecuencias




Figura 4. Distribución de brotes por tipo de huésped. Fuente: Elaboración propia.

económicas y productivas. Sin embargo, la presencia de una proporción muy similar de registros en fauna silvestre pone de manifiesto el papel fundamental que desempeñan estas poblaciones en la persistencia y dispersión geográfica de la enfermedad. En conjunto, la distribución observada sugiere que la dinámica epidemiológica de la IAAP no puede interpretarse exclusivamente desde el ámbito doméstico ni desde el silvestre, sino como un sistema interconectado en el que ambos entornos participan de forma relevante.

Por otro lado, las categorías Captive (1,8 %) y Feral (0,1 %) presentan una representación muy reducida dentro del *dataset*. Aunque su peso cuantitativo es escaso, resultan de interés porque pueden actuar como interfaces entre poblaciones domésticas y silvestres, especialmente en contextos donde existen contactos indirectos o compartición de espacios y recursos. No obstante, el reducido número de registros disponibles limita la posibilidad de extraer conclusiones robustas sobre su papel específico en la transmisión de la enfermedad.

5.1.3. Evolución temporal 2005-2026.

Esta gráfica representa la evolución temporal del número de brotes registrados a lo largo de los años, abarcando la totalidad del periodo disponible en el *dataset*, comprendido entre 2005 y 2026. Esta representación permite identificar si la actividad registrada se ha mantenido estable a lo largo del tiempo o si, por el contrario, existen periodos de cambio significativo en el volumen de brotes notificados, aspecto especialmente relevante dada la actualidad del fenómeno objeto de estudio.




Figura 5. Evolución temporal de brotes de gripe aviar 2005-2026. Fuente: Elaboración propia.

■ Discusión de Resultados:

La figura 5 muestra la evolución temporal del número de brotes de gripe aviar registrados entre 2005 y 2026, revelando una tendencia general de incremento progresivo con una marcada aceleración a partir de 2020. Durante el periodo comprendido entre 2005 y 2019, la actividad registrada se mantiene en niveles relativamente bajos y con fluctuaciones moderadas, con valores que oscilan mayoritariamente por debajo de los 2.000 brotes anuales, a excepción de un repunte puntual en torno a 2017. Este comportamiento sugiere una circulación del virus contenida o, alternativamente, una capacidad de detección y notificación aún limitada en ese periodo.

A partir de 2020 se produce un cambio de patrón sustancial, con un crecimiento sostenido que culmina en el pico máximo de 11.623 brotes registrado en 2022, el valor más elevado de toda la serie histórica. Este máximo se corresponde con la expansión simultánea del subtipo H5N1 por Europa, América y África, en lo que constituye el episodio de mayor magnitud documentado hasta la fecha. Tras este pico, la serie muestra una moderación en 2023, seguida de un nuevo repunte significativo en 2025, lo que indica que la dinámica epidemiológica no ha retornado a los niveles previos a 2020, sino que se mantiene en una fase de actividad elevada con oscilaciones interanuales notables.

No obstante, la interpretación de esta tendencia creciente requiere cautela. El incremento en el número de brotes registrados no refleja necesariamente, de forma exclusiva, una mayor expansión real del virus. Factores como el fortalecimiento de los sistemas de vigilancia epidemiológica, la mejora de la capacidad diagnóstica a escala global, la ampliación de la cobertura de las bases de datos internacionales como la OIE/WOAH, y una mayor concienciación institucional sobre

la enfermedad, pueden haber contribuido de forma significativa al aumento de los registros disponibles. En consecuencia, la serie temporal debe interpretarse como el resultado combinado de una posible expansión real del virus y de una mejora progresiva en la detección y notificación de eventos, sin que sea posible disociar con precisión la contribución relativa de cada uno de estos factores a partir de los datos representados [29].

5.1.4. Densidad de brotes (Acumulada).

En esta figura 6 se puede observar una gran concentración de puntos de calor en la zona de Europa. El mapa de densidad se generó mediante una técnica estadística llamada Estimación de Densidad por Kernel (KDE), que permite transformar un conjunto de puntos geográficos discretos (en este caso, las coordenadas de cada brote) en una superficie continua que representa la concentración relativa de eventos en cada zona del mapa.




Figura 6. Densidad geográfica de brotes de gripe aviar (2005-2026).

Fuente: Elaboración propia.

El funcionamiento básico es el siguiente: para cada punto del mapa, el algoritmo calcula cuántos brotes existen en su entorno cercano, ponderando su contribución en función de la distancia, de modo que los brotes más próximos contribuyen más que los lejanos. El resultado es una superficie donde las zonas con mayor acumulación de brotes aparecen con colores más intensos, y las zonas sin registros aparecen como fondo neutro. El resultado es una superficie donde las zonas con mayor acumulación de brotes aparecen con colores más intensos, y las zonas sin registros aparecen como fondo neutro.

En la implementación realizada se utilizó la función *gaussian_kde* de la librería *scipy* de Python, con un parámetro de suavizado (*bw_method*) de 0.3, que controla el radio de influencia de cada

punto. Los valores más bajos producen mapas más detallados pero con más ruido, mientras que valores más altos generan superficies más suavizadas.

Para ayudar a la comprensión de cómo evoluciona el brote, se procede a realizar una nueva serie de gráficos de densidad, pero ahora por intervalos de años.

Esta serie de gráficos muestra el desglose por franjas de tiempo de la densidad geográfica de brotes, con el objetivo de ilustrar cómo la distribución espacial de la enfermedad ha evolucionado a lo largo del periodo estudiado. Los periodos representados abarcan intervalos de tres años desde 2005 hasta 2026. Es importante advertir que cada mapa emplea una escala de color independiente: el tono más intenso de cada figura representa el valor máximo de la función de densidad KDE para ese trienio concreto, sin que dicho valor sea comparable en magnitud con el de los mapas restantes. En consecuencia, una intensidad de color equivalente en dos figuras distintas no implica un volumen similar de brotes, sino únicamente una concentración relativa máxima dentro de cada periodo. Esta convención de escala independiente permite apreciar con mayor claridad los patrones espaciales propios de cada trienio, pero exige que la comparación entre periodos se realice atendiendo a la posición geográfica de los focos, no a la intensidad del color.




Figura 7. Densidad geográfica de brotes de gripe aviar entre (a) 2004 y 2007 y entre (b) 2008 y 2011. Fuente: Elaboración Propia




Figura 8. Densidad geográfica de brotes de gripe aviar entre (a) 2012 y 2015 y entre (b) 2016 y 2019. Fuente: Elaboración Propia.




Figura 9. Densidad geográfica de brotes de gripe aviar entre (a) 2020 y 2023 y entre (b) 2024 y 2026. Fuente: Elaboración Propia

■ Discusión de Resultados:

La figura 6 muestra la distribución geográfica acumulada de los brotes de gripe aviar registrados entre 2005 y 2025, representada mediante un mapa de densidad de kernel a escala mundial. El rasgo más llamativo de la visualización es la existencia de un núcleo de máxima concentración situado en Europa central y occidental, que abarca aproximadamente desde Francia y los Países Bajos hasta Polonia y Ucrania, y que domina visualmente el conjunto del mapa con una intensidad muy superior al resto de regiones. Fuera de este núcleo, el mapa refleja focos secundarios de densidad notablemente inferior en el este y sudeste asiático, en la costa este de América del Norte, y en puntos dispersos del África subsahariana y América del Sur, mientras que el hemisferio sur y las regiones polares presentan una presencia prácticamente testimonial de registros.

Esta concentración en Europa debe interpretarse teniendo en cuenta que el *dataset* acumula datos desde 2005 hasta 2026, y que la mayoría de los registros más recientes corresponden precisamente a eventos europeos. Dado que los años más recientes de la serie concentran el mayor volumen de brotes de toda la historia registrada, tal y como se observa en la evolución temporal representada en la figura 5, es coherente que el peso geográfico del acumulado total recaiga sobre la región que protagonizó esa expansión reciente. Este desplazamiento respecto al patrón histórico es epidemiológicamente muy relevante: antes de 2020, Asia había sido la región con mayor carga de brotes documentados, especialmente durante los primeros episodios de expansión del H5N1. El hecho de que Europa haya pasado a ocupar ese rol indica un cambio estructural en la dinámica de circulación del virus, probablemente vinculado a su consolidación en las poblaciones de aves silvestres migratorias que atraviesan el continente. Esta endemización en el reservorio silvestre tiene implicaciones directas sobre las estrategias de vigilancia y control en el ámbito doméstico, al introducir un foco de circulación viral persistente y geográficamente amplio que trasciende los episodios puntuales de transmisión documentados

en periodos anteriores.

5.1.5. Brotes según zonas geográficas.

La figura 10 representa, en valores absolutos, la distribución del número de brotes según la región geográfica (*region*) en la que se registró cada uno, incorporando además el porcentaje que cada región representa sobre el total del *dataset*. Esta representación permite cuantificar de forma precisa el patrón espacial observado en el mapa de densidad del apartado anterior, comprobando si la concentración visual detectada en una región concreta se corresponde con un peso proporcional similar en el conjunto de los datos




Figura 10. Distribución de brotes por región geográfica. Fuente: Elaboración propia.

■ Discusión de Resultados:

La figura 10 cuantifica en valores absolutos y porcentuales la distribución regional de los brotes de gripe aviar registrados en el periodo 2004–2025, complementando y precisando numéricamente el patrón espacial descrito en la figura 6. Europa concentra el 60,6 % del total de registros con 32.348 brotes, lo que confirma su posición dominante en el conjunto del *dataset* y dota de sustento cuantitativo a la concentración geográfica observada en el mapa de densidad previo. A considerable distancia se sitúan las Américas con un 18,0 % y Asia y el Pacífico con un 14,3 %, mientras que África alcanza el 6,5 %, y Oriente Medio y la categoría sin región asignada presentan una representación prácticamente residual.

La coherencia entre este apartado y el anterior: la dominancia europea que el mapa de densidad expresaba de forma visual encuentra aquí su correlato numérico exacto. No obstante, esta distribución debe leerse a la luz de lo expuesto anteriormente sobre el sesgo temporal del *dataset*: dado que los años 2021–2025 concentran el mayor volumen de brotes de toda la serie histórica, y que esos registros recientes corresponden mayoritariamente a eventos europeos, el peso de Europa en el acumulado total resulta amplificado respecto a lo que reflejaría una distribución homogénea en el tiempo. La proporción relativamente modesta de Asia y el Pacífico, región que históricamente fue el epicentro de la IAAP durante las dos primeras décadas del siglo, ilustra precisamente ese desplazamiento geográfico estructural que se ha producido en la dinámica de circulación del virus. En conjunto, ambas figuras 6 y 10 ofrecen una imagen coherente y complementaria de un sistema epidemiológico que ha reconfigurado su geografía de forma significativa en los últimos años.

5.1.6. Valores de distancia a humedales.

Esta gráfica representa, mediante diagramas de caja (*boxplot*), la distribución de la distancia al humedal Ramsar más cercano (*dist_ramsar_km*) para cada orden taxonómico (*Orden_agrupado*), permitiendo identificar tanto los valores centrales (mediana, rango intercuartílico) como los valores atípicos (*outliers*) de cada grupo.




Figura 11. Distancia al humedal Ramsar más cercano por orden taxonómico. Fuente: Elaboración propia.

Una primera versión (figura 11) de esta representación, generada sin restricción en la escala del eje de ordenadas, resultó difícilmente interpretable: la presencia de valores atípicos muy alejados del resto comprimía visualmente la representación de las cajas, dificultando la lectura de los valores

centrales (mediana, cuartiles) en varios de los grupos. Por este motivo, se generó una nueva figura acotando el eje Y al intervalo [0, 1000], lo que permite apreciar con mayor claridad la información correspondiente a los valores centrales de cada distribución, a costa de no representar gráficamente los valores atípicos más extremos, dando lugar a la figura 12.




Figura 12. Distancia al humedal Ramsar más cercano por orden taxonómico (intervalo 0–1000 km). Fuente: Elaboración propia.

■ Discusión de Resultados:

Ambas figuras 11 y 12 representan la misma información, pero difieren en su presentación visual: la figura 11 corresponde a la salida directa del código original, mientras que la figura 12 incorpora mejoras estéticas que facilitan su lectura e interpretación. Por ello, el análisis se apoyará en la figura 12. Esta representa mediante diagramas de caja la distancia al humedal Ramsar más cercano para cada orden taxonómico presente en el *dataset*, permitiendo evaluar la relación entre la proximidad a estos ecosistemas acuáticos protegidos y la distribución de los brotes registrados. La mediana global de 69,7 km, representada mediante la línea naranja discontinua, actúa como referencia comparativa entre grupos y constituye el eje interpretativo central de la figura 12.

Los órdenes que se sitúan claramente por debajo de esa mediana global son precisamente los que agrupan aves acuáticas y costeras: Charadriiformes, Anseriformes, Accipitriformes y Gruiformes presentan distribuciones muy concentradas en valores bajos, con medianas que no superan los 70 km y cajas de rango intercuartílico reducidas, lo que indica una asociación consistente y poco variable entre estos grupos y la proximidad a humedales. Este patrón es ecológicamente coherente, ya que patos, gansos, grullas y limícolas costeros son habitantes naturales o habituales de estos ecosistemas, que constituyen además los principales nodos de

congregación durante las rutas migratorias. La estrecha vinculación de estos órdenes con los humedales Ramsar refuerza la hipótesis de que estos espacios actúan como focos preferentes de transmisión y amplificación del virus entre aves silvestres.

En contraste, Galliformes, Carnivora y Artiodactyla presentan medianas por encima de la línea de referencia, y notablemente una mayor dispersión en sus distribuciones, especialmente en los dos últimos grupos, cuyos bigotes y valores atípicos alcanzan distancias muy superiores al resto. En el caso de los Galliformes, este alejamiento de los humedales es coherente con su condición predominantemente doméstica o de granja, lo que apunta a que su elevada representación en el *dataset*, ya comentada en figuras anteriores, responde a una transmisión de carácter secundario recibida desde el reservorio silvestre y no a un contacto directo con los focos acuáticos. La mayor variabilidad observada en Carnivora refleja por su parte la amplitud de territorios que caracteriza a estos mamíferos, cuya exposición al virus se produciría de forma oportunista a través de la cadena trófica, en contextos geográficos muy diversos y no necesariamente ligados a entornos húmedos.

5.1.7. Distribución de brotes - Dentro de áreas protegidas vs fuera.

Esta figura 13 se representa, para cada orden taxonómico (*Orden_agrupado*), la proporción de brotes localizados dentro de áreas protegidas IBA/KBA confirmadas frente a aquellos situados fuera de cualquier área catalogada, mostrando dicha distribución tanto en valores absolutos como en términos porcentuales. Esta representación permite valorar si la pertenencia a un área protegida constituye un factor diferenciador entre los distintos órdenes, o si, por el contrario, los brotes tienden a concentrarse fuera de estas áreas con independencia del grupo taxonómico considerado.




Figura 13. Distribución de brotes dentro y fuera de áreas protegidas IBA/KBA por orden taxonómico. Fuente: Elaboración propia.

■ **Discusión de Resultados:**

La figura 13 presenta la distribución de brotes de gripe aviar en función de su localización dentro o fuera de áreas protegidas IBA/KBA, desglosada por orden taxonómico tanto en valores absolutos como en porcentaje. El dato más relevante del conjunto es que aproximadamente el 80 % de los registros totales se localiza fuera de áreas catalogadas, lo que establece desde el inicio un contexto interpretativo importante: la circulación del virus no queda circunscrita a los espacios de mayor valor para la biodiversidad, sino que se extiende de forma mayoritaria por entornos no protegidos.

Sin embargo, esta proporción global no es uniforme entre grupos taxonómicos, y es precisamente esa heterogeneidad la que aporta valor interpretativo a la figura 13. Anseriformes y Charadriiformes son los órdenes con mayor proporción de brotes dentro de áreas IBA/KBA, con valores en torno al 35–38 %, seguidos de Accipitriformes y Gruiformes con porcentajes intermedios de entre el 25 y el 35 %. Este patrón es coherente con lo observado en la figura 12 anterior sobre distancias a humedales Ramsar: los mismos grupos que mostraban mayor proximidad a estos ecosistemas son ahora los que presentan mayor solapamiento con áreas protegidas catalogadas, lo que refuerza la imagen de estas aves acuáticas y costeras como los grupos más estrechamente vinculados a los espacios de congregación natural donde el virus circula con mayor intensidad entre poblaciones silvestres.

En el extremo opuesto, Galliformes, Carnivora y Artiodactyla presentan los porcentajes más bajos de presencia dentro de áreas IBA/KBA, por debajo del 10 %, lo que es consistente con su condición predominantemente doméstica o terrestre ya descrita en figuras anteriores. La práctica totalidad de sus brotes se produce en entornos no catalogados, alejados de los focos de biodiversidad acuática, lo que confirma que su exposición al virus responde a dinámicas de transmisión secundaria desde el reservorio silvestre y no a una participación directa en los ciclos de circulación asociados a estos espacios protegidos. En conjunto, la figura 13 sugiere que una estrategia de vigilancia basada exclusivamente en áreas IBA/KBA, aunque útil como sistema de detección temprana en poblaciones silvestres, dejaría fuera del foco de atención la gran mayoría de los eventos registrados, particularmente aquellos de origen doméstico que constituyen el grueso cuantitativo del *dataset*.

5.1.8. Relación de brotes en aves vs mamíferos.

Con el objetivo de explorar la posible relación espacial entre los brotes de gripe aviar detectados en aves y los casos registrados en mamíferos, se representaron ambos conjuntos de datos mediante

mapas de densidad espacial (KDE), y se complementó esta representación visual con un análisis cuantitativo basado en los coeficientes de correlación de Pearson y Spearman, calculados sobre las matrices de densidad resultantes. A partir de la representación visual, puede apreciarse cierto solapamiento geográfico entre algunas áreas de concentración de casos en ambos grupos, si bien las escalas de densidad de ambos mapas son independientes entre sí y no resultan comparables en magnitud, por lo que dicha apreciación se refiere a la ubicación de los *hotspots* y no a la intensidad relativa entre ambos grupos.




Figura 14. Comparación de hotspots: aves (azul) vs mamíferos (rojo).
Fuente: Elaboración propia.

Sin embargo, la interpretación visual de estos resultados debe realizarse con cautela por dos motivos. En primer lugar, existe una diferencia considerable en el volumen de datos empleado en cada distribución: mientras que la agrupación correspondiente a aves incluye 51.391 registros, los casos detectados en mamíferos ascienden a 1.979, una diferencia que refleja principalmente un sesgo de muestreo en los sistemas de vigilancia epidemiológica (considerablemente más desarrollados para aves de granja y aves silvestres que para mamíferos) y no necesariamente la ausencia de transmisión entre grupos. En segundo lugar, esta diferencia de escala puede influir significativamente tanto en la apariencia visual de los mapas como en las densidades estimadas mediante KDE, condicionando la interpretación de cualquier solapamiento o divergencia observados visualmente.

Con el fin de cuantificar objetivamente la relación entre ambas distribuciones espaciales, se calcularon el coeficiente de Pearson, que evalúa la existencia de una relación lineal entre las matrices de densidad, y el coeficiente de Spearman, que evalúa la existencia de una relación monótona con independencia de su linealidad. La combinación de ambos coeficientes permite una caracterización más robusta del grado de dependencia espacial, ya que una divergencia entre ellos (correlación de Spearman elevada con Pearson reducido, o viceversa) aportaría información adicional sobre la naturaleza de esa relación que ninguno de los dos por separado sería capaz de revelar.

Cálculo de la correlación de Pearson entre densidades KDE.

- El coeficiente de correlación de Pearson obtenido fue:

$$r = 0.1931$$

$$p < 1 \times 10^{-6}$$

Este resultado indica la existencia de una asociación positiva débil entre ambas distribuciones espaciales. Aunque la correlación observada resulta estadísticamente significativa, su intensidad es reducida, por lo que no puede afirmarse la existencia de una relación espacial fuerte entre los brotes registrados en aves y los casos detectados en mamíferos. Dicho de otra forma, la relación lineal entre ambos conjuntos es débil.

Cálculo de la correlación de Spearman entre densidades KDE.

- El coeficiente de correlación de Spearman obtenido fue:

$$\rho = 0.7816$$

$$p < 1 \times 10^{-6}$$

Este resultado indica la existencia de una asociación positiva fuerte entre ambas distribuciones espaciales. Aunque la correlación observada resulta estadísticamente significativa, su interpretación debe distinguirse de la relación lineal, ya que el coeficiente de Pearson sugiere una asociación lineal débil. En consecuencia, los resultados son compatibles con la existencia de una relación monótona no lineal entre ambas distribuciones espaciales.

No obstante, este valor debe contextualizarse dada la naturaleza de los datos transformados, como se discute a continuación.

■ Discusión de Resultados:

La comparación entre los coeficientes de correlación de Pearson y Spearman permite caracterizar la relación existente entre ambas distribuciones espaciales desde una perspectiva puramente estadística.

El coeficiente de Pearson sugiere una asociación lineal débil entre las densidades espaciales derivadas de los brotes en aves y mamíferos. Este resultado indica que no existe una relación

lineal global consistente entre ambas matrices de densidad, lo que implica que las variaciones en una distribución no explican de forma proporcional las variaciones en la otra.

Por otro lado, el coeficiente de Spearman muestra un valor considerablemente más elevado, lo que indica la presencia de una relación monótona entre ambas distribuciones. Este resultado sugiere que, aunque no exista una correspondencia lineal directa, sí puede existir cierta coherencia en el orden relativo de las intensidades espaciales, es decir, regiones con mayor densidad en un conjunto tienden a presentar también valores relativamente elevados en el otro.

Sin embargo, esta discrepancia entre ambos coeficientes debe interpretarse desde la naturaleza del dato analizado. En particular, el uso de matrices de densidad obtenidas mediante KDE implica una transformación del espacio original en una superficie suavizada, donde los valores ya no representan observaciones independientes, sino estimaciones continuas con dependencia espacial inherente. Esto puede inducir correlaciones elevadas en términos de ranking (Spearman), sin que necesariamente exista una relación lineal o estructural fuerte entre los datos originales.

Adicionalmente, la diferencia de escala entre ambos conjuntos de datos, así como la concentración desigual de observaciones geográficas, puede influir en la forma de las distribuciones de densidad y en la sensibilidad de los coeficientes utilizados.

En este contexto, los resultados obtenidos deben interpretarse como una descripción de similitudes parciales en la estructura espacial de las distribuciones, más que como evidencia de una relación funcional directa entre ambas variables.

En consecuencia, desde el punto de vista matemático, se concluye que:

- No se observa una relación lineal global de magnitud apreciable entre ambas distribuciones espaciales.
- Existe cierta coherencia en la ordenación relativa de las densidades espaciales.
- La relación observada depende fuertemente de la transformación KDE y de la agregación espacial de los datos.
- Por tanto, la dependencia detectada es de carácter estructural en el espacio transformado, más que una relación directa entre observaciones originales.

Estos resultados evidencian la importancia de considerar la naturaleza de las transformaciones espaciales y las propiedades estadísticas de las métricas utilizadas en el análisis de datos georreferenciados.

5.2. *Machine Learning*.

En esta sección se presentan los resultados obtenidos tras la aplicación de los modelos de aprendizaje automático sobre el *dataset* procesado. Los resultados se organizan en cinco bloques: el preprocesamiento aplicado al *dataset*, los resultados del modelo principal Random Forest, los resultados del modelo de contraste Regresión Logística, la comparativa entre ambos modelos y finalmente la aplicación regional sobre España.

El *dataset* de partida para esta fase es el resultado del proceso ETL e integración espacial descrito en los apartados anteriores, 53.370 registros con 19 variables, de los cuales se seleccionaron 11 como features y una como variable objetivo (Orden_agrupado). La variable objetivo presenta un desbalance notable, con Galliformes representando el 50,2 % de los registros y clases como Carnivora o Artiodactyla sin superar el 2 %.

5.2.1. Preprocesamiento para *Machine Learning*.

El preprocesamiento constituye la fase inicial del *pipeline* de aprendizaje automático y tiene como objetivo preparar el *dataset* para garantizar la calidad, coherencia y utilidad de las variables empleadas en los modelos predictivos. En esta etapa se realizan tareas como la selección de características relevantes, el tratamiento de valores ausentes y la transformación de variables, asegurando que los algoritmos puedan operar de forma eficiente y obtener resultados fiables.

Selección de *features*.

De las 16 variables disponibles en el *dataset*, se seleccionaron 11 como predictores. Se excluyeron *geometry* por ser una variable geométrica no procesable directamente por los algoritmos; *Orden* por ser la variable de la que deriva el target; *Reporting_date* al estar ya representada por año; *Species* por su alta cardinalidad; y *SitRecID* por ser un identificador sin valor predictivo. Las features finales fueron: *Longitude*, *Latitude*, *wild_type*, *Ave_mm*, *region*, *IbaStatus*, *KbaStatus*, *KbaClass*, *SitAreaKm2*, *dist_ramsar_km* y año.

Tratamiento de valores ausentes

Las variables *IbaStatus*, *KbaStatus* y *KbaClass* presentaban en torno al 80 % de valores ausentes, correspondientes a brotes localizados fuera de áreas IBA/KBA. Estos valores no representan datos perdidos sino información real (la ausencia de un área protegida en la localización del brote) por lo que se imputaron con categorías explícitas: *Sin_IBA* y *Sin_KBA* respectivamente. La variable *SitAreaKm2* se imputó con 0 bajo el mismo criterio.

Encoding de variables categóricas

Las variables categóricas se codificaron mediante *LabelEncoder* de *scikit-learn*, proceso que afectó

a seis variables predictoras: *wild_type*, *Ave_mm*, *region*, *IbaStatus*, *KbaStatus* y *KbaClass*. Entre ellas, *IbaStatus* y *KbaStatus* son variables dicotómicas cuyos valores originales eran cadenas de texto (*Sin_IBA/confirmed* y *Sin_KBA/confirmed* respectivamente), por lo que la codificación resultó igualmente necesaria para su incorporación al modelo. Las cinco variables restantes (*Longitude*, *Latitude*, *SitAreaKm2*, *dist_ramsar_km* y *año*) ya presentaban formato numérico y se incorporaron directamente sin transformación. La variable objetivo *Orden_agrupado* fue codificada mediante un *LabelEncoder* independiente. Tras este proceso, el *dataset* de entrenamiento quedó compuesto por 11 variables predictoras sobre un total de 53.370 registros.

División *train/test*

El *dataset* se dividió en 80 % entrenamiento (42.696 registros) y 20 % test (10.674 registros), con estratificación por clases para garantizar que la proporción de cada orden taxonómico es representativa en ambos subconjuntos.

Función de aptitud

En cuanto a la función de aptitud empleada durante el entrenamiento, cada modelo utiliza un criterio distinto. El modelo *Random Forest* emplea la impureza de Gini como criterio de división en cada nodo de cada árbol (*criterion='gini'*, valor por defecto de *scikit-learn*): en cada partición, el algoritmo selecciona la variable y el umbral que maximizan la reducción de impureza entre las clases resultantes. La Regresión Logística, por su parte, minimiza la pérdida logarítmica (*log-loss*) mediante el optimizador *lbfgs* (valor por defecto de *scikit-learn*), que aproxima el gradiente de segundo orden para encontrar los parámetros que mejor separan las clases en el espacio transformado. Adicionalmente, dado que la Regresión Logística es sensible a la escala de las variables, el conjunto de entrenamiento fue normalizado previamente mediante *StandardScaler* antes de su ajuste, paso que no fue necesario para el *Random Forest*, cuyo criterio de división basado en umbrales es invariante a la escala de las variables predictoras.

5.2.2. Modelo principal: *Random Forest* (RF).

Métricas globales

El modelo *Random Forest* fue entrenado con 100 árboles, *class_weight='balanced'* y *random_state=42*, completando el entrenamiento en 2,9 segundos. Los resultados sobre el conjunto de test fueron:

- *Accuracy global*: 83,29 %
- *F1-score macro*: 0,73
- *F1-score weighted*: 0,83

Las tablas 5 y 6 detallan estos resultados por clase y de forma agregada, respectivamente. En ambas, la columna *Support* indica el número de instancias reales de cada clase en el conjunto de prueba.

Tabla 5. Informe de clasificación por clase ML

Clase	Precision	Recall	F1-score	Support
Accipitriformes	0.31	0.25	0.28	396
Anseriformes	0.72	0.76	0.74	2225
Artiodactyla	1.00	1.00	1.00	205
Carnivora	0.98	1.00	0.99	188
Charadriiformes	0.67	0.63	0.65	1066
Galliformes	1.00	0.99	1.00	5360
Gruiformes	0.70	0.76	0.73	378
Otros	0.49	0.49	0.49	856

Tabla 6. Resumen de métricas globales del modelo ML

Métrica	Precision	Recall	F1-score	Support
Accuracy			0.83	10674
Macro avg	0.73	0.74	0.73	10674
Weighted avg	0.83	0.83	0.83	10674

Las filas *Macro avg* y *Weighted avg* recogen dos formas complementarias de resumir el rendimiento global del modelo. *Macro avg* calcula la media aritmética simple de cada métrica sobre todas las clases, otorgando el mismo peso a cada orden taxonómico con independencia de su frecuencia en el *dataset*; este promedio es especialmente sensible al rendimiento del modelo en las clases minoritarias, ya que un fallo sistemático en una clase pequeña penaliza el promedio en la misma medida que un fallo equivalente en una clase mayoritaria. *Weighted avg*, por su parte, calcula la media ponderada de cada métrica usando como peso el número de registros de cada clase (*support*), de modo que las clases más frecuentes (en particular Galliformes, que concentra aproximadamente el 50 % de los registros globales) contribuyen en mayor medida al valor resultante. En este trabajo, la diferencia observada entre ambos promedios (*F1-score Macro avg* de 0,73 frente a *Weighted avg* de 0,83) refleja precisamente el desequilibrio taxonómico del *dataset*: el modelo rinde de forma notable en las clases más frecuentes, pero su rendimiento medio sobre el conjunto de clases (ponderando todas por igual) es inferior, lo que indica que las clases minoritarias presentan mayor dificultad de clasificación.

Este resultado es coherente con el uso de `class_weight='balanced'` durante el entrenamiento, que compensa parcialmente el desequilibrio pero no lo elimina por completo”. La fila *Accuracy* recoge la proporción de predicciones correctas sobre el total de instancias evaluadas.

El análisis por clase muestra un comportamiento heterogéneo. Galliformes, Artiodactyla y Carnivora obtienen *F1-score* prácticamente perfecto: 1,00, 1,00 y 0,99 respectivamente. Anseriformes y Gruiformes se sitúan en torno a 0,73-0,74, mientras que Charadriiformes alcanza 0,65. Los resultados menos satisfactorios corresponden a Otros: F1 de 0,49, esperable por su carácter heterogéneo, y Accipitriformes, con un F1 de 0,28.

El caso de Accipitriformes merece atención específica. Con 1.978 registros en el *dataset* no es una clase minoritaria, por lo que su bajo rendimiento no se debe a falta de ejemplos. El análisis de la matriz de confusión (figura 15) revela que el modelo confunde frecuentemente Accipitriformes con Anseriformes (150 casos mal clasificados) lo que sugiere que ambos grupos comparten características geográficas similares que el modelo no consigue distinguir a escala global.

Matriz de confusión *Random Forest* global

La diagonal principal concentra la mayoría de las predicciones correctas, siendo Galliformes el elemento más destacado por su volumen. Fuera de la diagonal, el cruce más relevante es el ya mencionado entre Accipitriformes y Anseriformes, con 150 casos mal clasificados, el error más frecuente del modelo a nivel global.




Figura 15.
Matriz de
confusión del
modelo Random
Forest global.
Fuente:
Elaboración
propia.

Importancia de variables

Las variables más relevantes para el modelo son *Longitude* (19,82 %) y *Latitude* (19,73 %), confirmando que la ubicación geográfica es el factor más determinante. Le siguen *wild_type* (16,68 %), *dist_ramsar_km* (13,83 %) y *Ave_mm* (13,76 %). En el extremo opuesto, *IbaStatus* (0,31 %), *KbaStatus* (0,31 %) y *KbaClass* (0,77 %) resultan prácticamente irrelevantes para el modelo, resultado que no invalida su uso en el EDA pero sí limita su capacidad predictiva en este contexto.




Figura 16. Importancia de variables en Random Forest. Fuente: Elaboración propia.

5.2.3. Modelo de contraste: Regresión Logística (RL).

La Regresión Logística fue entrenada con *class_weight='balanced'*, *max_iter=1000* y normalización previa mediante *StandardScaler*. El entrenamiento se completó en 7,9 segundos. Los resultados sobre el conjunto de test fueron:

- *Accuracy global*: 67,37 %
- *F1-score macro*: 0,56
- *F1-score weighted*: 0,67

Tabla 7. Informe de clasificación por clase RL

Clase	Precision	Recall	F1-score	Support
Accipitriformes	0.14	0.43	0.21	396
Anseriformes	0.58	0.22	0.31	2225
Artiodactyla	0.95	1.00	0.98	205
Carnivora	0.98	0.95	0.96	188
Charadriiformes	0.48	0.26	0.34	1066
Galliformes	0.98	0.99	0.98	5360
Gruiformes	0.22	0.89	0.35	378
Otros	0.35	0.27	0.31	856

Tabla 8. Resumen de métricas globales del modelo RL

Métrica	Precision	Recall	F1-score	Support
Accuracy			0.67	10674
Macro avg	0.58	0.63	0.56	10674
Weighted avg	0.74	0.67	0.67	10674

El modelo clasifica bien las clases con patrones más marcados: Galliformes (F1: 0,98), Artiodactyla (F1: 0,98) y Carnivora (F1: 0,96); pero presenta dificultades significativas con las clases intermedias: Anseriformes cae a F1 de 0,31, Gruiformes a 0,35 y Charadriiformes a 0,34.

Matriz de confusión Regresión Logística global

La diagonal principal sigue siendo el elemento más destacado, aunque con menor intensidad que en el *Random Forest*. Los patrones de confusión fuera de la diagonal difieren de los observados en el *Random Forest*, indicando que ambos modelos cometen errores de naturaleza distinta.




Figura 17. Matriz de confusión Regresión Logística global. Fuente: Elaboración propia.

5.2.4. Comparativa de modelos.

Random Forest vs Regresión Logística

La comparativa entre ambos modelos muestra una diferencia global de casi 16 puntos porcentuales en accuracy (83,29 % frente a 67,37 %) a favor del *Random Forest*. El análisis por clase revela matices importantes que van más allá del dato global.




Figura 18. Gráfico comparativa F1-score por clase RF vs LR. Fuente: Elaboración propia.

En las clases con patrones más definidos (Galliformes, Artiodactyla y Carnivora) la diferencia entre ambos modelos es mínima, de apenas 0,02 puntos sobre 1. Donde el *Random Forest* demuestra su superioridad de forma más clara es en las clases intermedias (Anseriformes y Gruiformes) donde obtiene F1 de 0,74 y 0,73 respectivamente, frente a valores que no superan 0,35 en la Regresión Logística. Esta diferencia evidencia que las fronteras de decisión entre estas clases no son linealmente separables, y que el *Random Forest* consigue modelarlas de forma mucho más efectiva gracias a su naturaleza no lineal.

Los casos de Accipitriformes y Otros presentan rendimiento bajo en ambos modelos, lo que sugiere que el problema en estas clases no es de modelo sino de datos.

Discusión de Resultados:

A tenor de los resultados obtenidos, la elección del *Random Forest* como modelo principal queda plenamente justificada. La mejora de casi 16 puntos en accuracy global no es marginal, y el análisis por clase demuestra que esta mejora es genuina; no se debe únicamente al peso de Galliformes sino a una capacidad superior para distinguir entre clases con patrones geográficos complejos.

La Regresión Logística cumple su papel como modelo de contraste: demuestra que un enfoque lineal no es suficiente para abordar este problema con garantías, y que la complejidad adicional del *Random Forest* está metodológicamente justificada. El principio de parsimonia aconseja preferir el modelo más simple que resuelva el problema con suficiente capacidad predictiva; sin embargo, en este caso dicho principio no puede aplicarse, ya que la Regresión Logística no alcanza un rendimiento aceptable: una diferencia de casi 16 puntos porcentuales en *accuracy global* y caídas de *F1-score* superiores a 0,38 puntos en clases intermedias como Anseriformes y Gruiformes justifican asumir la mayor complejidad del *Random Forest* a cambio de una ganancia real y sustancial en capacidad predictiva.

5.2.5. Aplicación sobre España.

Preparación del subconjunto español.

La aplicación del modelo sobre España requirió un proceso de preparación específico que conviene describir antes de presentar los resultados, dado que el subconjunto español presentó particularidades que no estaban presentes en el *dataset* global.

El punto de partida fue un subconjunto de 882 registros correspondientes a España, extraídos del *dataset* global durante la fase ETL. Sin embargo, este subconjunto carecía de dos variables necesarias para la aplicación del modelo que habían sido generadas con posterioridad a su extracción. La primera es *Orden_agrupado*, variable construida durante el preprocesamiento global agrupando los 22 órdenes

taxonómicos originales de la variable Orden en 8 clases, asignando la etiqueta 'Otros' a todos los órdenes con menos de 900 registros en el *dataset* global (véase apartado 5.2.1); su reconstrucción para el subconjunto español aplicó el mismo umbral y la misma lista de órdenes principales, garantizando la coherencia con el modelo entrenado. La segunda es año, variable derivada de *Reporting_date* mediante la extracción del componente anual (*Reporting_date.dt.year*), igualmente ausente en el subconjunto extraído y reconstruida aplicando la misma transformación.

La incorporación de la variable RIQUEZAESP (el índice de riqueza de especies por celda de 10x10 km disponible exclusivamente para España) presentó dificultades técnicas durante su integración con el subconjunto de brotes españoles. La operación natural para este tipo de dato sería una intersección punto-polígono: dado que cada brote dispone de coordenadas geográficas (*Longitude*, *Latitude*) y la capa RIQUEZAESP está organizada en una cuadrícula de polígonos, cabría esperar que cada punto cayera dentro de exactamente una celda. Sin embargo, esta aproximación generó dos problemas en la práctica. El primero fue una incompatibilidad en el sistema de referencia de coordenadas (CRS) entre ambas capas, que provocó la pérdida de 278 registros en el primer intento de unión espacial (de 882 registros iniciales se obtuvieron únicamente 604). El segundo fue la aparición de duplicados en registros cuyos puntos caían exactamente sobre la frontera entre dos celdas adyacentes, intersectando geométricamente con ambas de forma simultánea. La solución adoptada fue el uso de *BallTree* con métrica *haversine*, que prescinde de la intersección geométrica y asigna a cada brote la celda de riqueza más cercana de forma unívoca: el resultado fue un subconjunto completo de 882 registros sin duplicados ni pérdidas. La distancia media resultante entre cada brote y su celda asignada fue de 4,11 km, lo que sugiere que la cuadrícula RIQUEZAESP presenta una cobertura efectiva sobre el territorio español donde se localizan los registros de brotes, y que la asignación por proximidad constituye una aproximación metodológicamente válida.

El subconjunto español procede del mismo *dataset* global, por lo que requirió una revisión adicional de la fase ETL antes de abordar la codificación de variables categóricas. Durante la minería de datos, los valores de los atributos se emplearon directamente sin que su grafía exacta resultara determinante; sin embargo, al incorporar dichos atributos al *pipeline* de aprendizaje automático, la codificación exige que cada categoría presente una grafía uniforme en todo el conjunto de datos. La revisión detectó que la normalización aplicada en ETL, consistente en convertir cada valor a minúsculas salvo la inicial en mayúscula (`str.capitalize()`), se había aplicado únicamente a la variable *Orden*, dejando el resto de variables categóricas con variantes de grafía coexistentes: *wild_type*, *IbaStatus*, *KbaStatus* y *KbaClass* presentaban inconsistencias de capitalización, y *Ave_mm* contenía el valor *Indeterminado* sin equivalente en el modelo global. Estos casos se resolvieron mediante mapeos explícitos; el valor *Indeterminado* de *Ave_mm* fue asignado a *Aves* por ser la categoría taxonómicamente más próxima.

La distribución de clases en España difiere notablemente del *dataset* global. Mientras que a nivel global Galliformes representa el 50 % de los registros, en España la distribución es más equilibrada: Otros (27,4 %), Charadriiformes (24,0 %), Galliformes (21,1 %), Anseriformes (13,6 %), Gruiformes (8,3 %) y Accipitriformes (5,6 %). Cabe destacar que Carnivora y Artiodactyla no tienen representación en el subconjunto español.

La categoría *Otros* agrupa órdenes taxonómicos con escasa representación individual en el *dataset* global, lo que justificó su consolidación en una única clase durante la fase de preprocesamiento. Si bien esta agrupación introduce cierta heterogeneidad interna, su desglose en clases más específicas requeriría un volumen de registros por orden suficiente para garantizar la estabilidad del modelo, condición que no se cumple en el *dataset* disponible. Este aspecto constituye una limitación reconocida del trabajo y una línea de mejora para investigaciones futuras, en las que un mayor volumen de datos podría permitir una taxonomía más granular sin comprometer el rendimiento predictivo. Esta misma agrupación está presente en el modelo global (donde la categoría *Otros* agrupa 856 registros) sin que ello haya comprometido el rendimiento predictivo, lo que refuerza su validez como decisión metodológica coherente a lo largo de todo el trabajo.

Resultados *Random Forest* sobre España.

A diferencia del modelo global, en el que se realizó una partición explícita entre conjuntos de entrenamiento y test, la evaluación sobre España no implica un nuevo entrenamiento. El modelo de *Random Forest* empleado es el mismo entrenado sobre el *dataset* global, aplicado directamente sobre los 882 registros españoles en su totalidad. Por este motivo no existe división *train/test* en esta fase: el conjunto español actúa íntegramente como conjunto de evaluación externo. Las variables de entrada son las mismas 11 features del modelo global (excluida RIQUEZAESP, que no formó parte del entrenamiento) y la variable de salida es igualmente *Orden* agrupado.

Tal como se estableció en la fase de diseño metodológico, el subconjunto español fue reservado expresamente como conjunto de evaluación externo, quedando excluido del entrenamiento global. El modelo *Random Forest* global se aplica directamente sobre los 882 registros españoles en su totalidad, utilizando las mismas 11 *features* (excluida RIQUEZAESP, que no formó parte del entrenamiento) y la misma variable objetivo *Orden* agrupado.

Los resultados obtenidos son los siguientes:

- *Accuracy global*: 93,08 %
- *F1-score macro*: 0,92

- *F1-score weighted*: 0,93

Tabla 9. Informe de clasificación por clase ML-ES

Clase	Precision	Recall	F1-score	Support
Accipitriformes	0.88	0.92	0.90	49
Anseriformes	0.89	0.76	0.82	120
Charadriiformes	0.99	0.96	0.97	212
Galliformes	1.00	0.99	1.00	186
Gruiformes	0.89	0.97	0.93	73
Otros	0.88	0.93	0.90	242


Tabla 10. Resumen de métricas globales del modelo ML-ES

Métrica	Precision	Recall	F1-score	Support
Accuracy			0.93	882
Macro avg	0.92	0.92	0.92	882
Weighted avg	0.93	0.93	0.93	882

El análisis por clase muestra mejoras generalizadas respecto al test global. Las más llamativas son las de Accipitriformes (que pasa de F1 0,28 global a 0,90 en España) y Charadriiformes (de 0,65 a 0,97). Galliformes mantiene su F1 de 1,00 en ambos contextos.

Matriz de confusión sobre España.

La diagonal principal concentra la gran mayoría de las predicciones correctas, con una densidad notablemente superior a la observada en el test global. El único error destacable fuera de la diagonal es el cruce entre Anseriformes y Otros, con 23 casos mal clasificados; coherente con la naturaleza heterogénea de la clase Otros en España, que agrupa órdenes minoritarios algunos de los cuales comparten hábitat con los Anseriformes.



Comparativa global vs España.

La comparativa muestra una mejora generalizada en todas las clases, con diferencias que oscilan entre los 0,62 puntos en Accipitriformes y los prácticamente nulos en Galliformes.




Figura 20. Gráfico comparativa F1-score global vs España. Fuente: Elaboración propia.

Discusión de Resultados:

Los resultados obtenidos sobre España constituyen el hallazgo más relevante de la fase de *Machine Learning*. Dado que el subconjunto español fue excluido expresamente del entrenamiento global, esta evaluación constituye una validación externa en sentido estricto, lo que refuerza la solidez de los resultados. El hecho de que un modelo entrenado con datos globales generalice con un 93 % de *accuracy* sobre un subconjunto regional específico sugiere que los patrones geográficos aprendidos a escala mundial son transferibles y robustos.

La mejora espectacular en Accipitriformes (de 0,28 a 0,90) tiene una explicación geográfica clara. A nivel global, el modelo confundía las rapaces con aves acuáticas por sus similitudes en coordenadas y proximidad a humedales. En España, la clara delimitación entre los ecosistemas de sierra y montaña (hábitat característico de las rapaces) y los humedales costeros e interiores (donde predominan Anseriformes y Charadriiformes) permite al modelo distinguirlos con mucha mayor precisión.

Desde el punto de vista computacional, estos resultados validan tanto la metodología de integración espacial aplicada en la fase ETL como la elección del *Random Forest* como modelo principal. Las variables geográficas (coordenadas y distancia a humedales) que mayor peso tuvieron en la feature importance son precisamente las que permiten al modelo generalizar bien sobre territorios específicos como España.

La interpretación de estos resultados desde el punto de vista de la vigilancia epidemiológica queda fuera del alcance de este trabajo y se traslada a los especialistas en la materia como línea de análisis complementaria.

5.3. Síntesis de resultados por objetivos.

La tabla 11 recoge una síntesis de los objetivos del trabajo desarrollados, junto con los principales indicadores de resultado obtenidos en cada uno de ellos.

Tabla 11. Resumen de objetivos e indicadores clave

Objetivo	Indicador clave
ETL e integración	53.370 registros, 19 variables, 5 fuentes integradas
EDA	Galliformes = 50,2 %; KDE global; serie 2005–2026
taxonómico/espacial/temporal	
Correlación	Pearson $r = 0,19$; Spearman $\rho = 0,78$
aves–mamíferos	

Objetivo	Indicador clave
Importancia de variables	RF: acc. 83,3 %, F1-macro 0,73; LR: acc. 67,4 %, F1-macro 0,56; Longitud/Latitud dominantes; IBA/KBA con peso reducido
Validación sobre España	RF-España: acc. 93,1 %, F1-macro 0,92
Objetivo General	<i>Pipeline</i> completo ETL → EDA → ML → validación regional

6. Conclusiones y líneas futuras.

En este capítulo se presentan las principales conclusiones obtenidas durante el desarrollo del trabajo, articuladas en tres niveles: el grado de cumplimiento del objetivo general, la evaluación explícita de cada objetivo específico con referencia directa a los resultados obtenidos, y las líneas de investigación futura que abre el trabajo.

6.1. Evaluación del objetivo general.

En este trabajo se han desarrollado modelos predictivos basados en minería de datos y aprendizaje automático para identificar y caracterizar patrones espaciales, temporales y taxonómicos asociados a los brotes de IAAP, evaluando la capacidad de las variables geográficas y ecológicas para describir la relación entre los brotes en aves silvestres y la aparición de casos en mamíferos. El modelo *Random Forest* alcanzó una precisión global del 83 %, frente al 67 % de la Regresión Logística utilizada como contraste.

El trabajo ha permitido desarrollar un proceso completo que abarca desde la integración y preparación de datos procedentes de múltiples fuentes hasta el análisis exploratorio, el estudio de relaciones espaciales entre especies y la construcción de modelos predictivos. Los resultados obtenidos sugieren que las técnicas empleadas son capaces de extraer información relevante a partir de los datos disponibles y apuntan a la existencia de patrones espaciales y taxonómicos identificables.

Más allá de los resultados obtenidos, este trabajo ha supuesto una aproximación práctica a los desafíos que implica aplicar técnicas de minería de datos y aprendizaje automático sobre datos reales. La necesidad de gestionar información heterogénea, documentar decisiones técnicas y analizar críticamente los resultados obtenidos ha puesto de manifiesto que gran parte del valor de estos proyectos no reside únicamente en los modelos construidos, sino también en la comprensión del problema, la calidad de los datos y el análisis crítico de las evidencias disponibles.

6.2. Evaluación de los objetivos específicos.

En conjunto, el trabajo ha permitido explorar de forma práctica las posibilidades y limitaciones de la minería de datos y el aprendizaje automático aplicados al ámbito de la vigilancia epidemiológica.

6.2.1. Integración y preparación del *dataset* analítico.

La fase de integración permitió construir un *dataset* analítico único compuesto por 53.370 registros procedentes de cinco fuentes de información epidemiológica y geográfica. El proceso ETL resolvió

diferencias de formato, estructura y representación espacial, incorporando variables relacionadas con áreas de interés para la biodiversidad y proximidad a humedales protegidos.

El resultado fue un conjunto de datos coherente y preparado para su explotación analítica, que sirvió de base para los análisis exploratorios, los estudios de correlación espacial y el desarrollo de los modelos predictivos. La experiencia obtenida apunta a que la calidad y consistencia de la fase de integración constituyen un factor relevante para la utilidad de los análisis posteriores.

6.2.2. Identificación de patrones taxonómicos, espaciales y temporales.

El análisis exploratorio permitió caracterizar la distribución de los brotes desde una perspectiva taxonómica, espacial y temporal. Desde el punto de vista taxonómico, el orden Galliformes concentró el 50,2 % de los registros analizados, lo que refleja una distribución claramente desigual entre grupos biológicos.

El análisis espacial mostró concentraciones geográficas bien definidas, y el análisis temporal evidenció una aceleración marcada en el periodo 2020–2026, compatible con las tendencias descritas en la bibliografía sobre la expansión reciente de la enfermedad. Estos hallazgos sugieren que la distribución de los brotes no responde a un comportamiento aleatorio, sino que presenta estructuras espaciales y temporales identificables que pueden ser aprovechadas en tareas de vigilancia epidemiológica.

6.2.3. Identificación y caracterización de la relación entre brotes en aves y mamíferos.

El análisis de correlación entre las distribuciones espaciales de aves y mamíferos permitió identificar comportamientos diferenciados según la métrica empleada. El coeficiente de Pearson ($r = 0,19$) mostró una asociación lineal débil, mientras que el coeficiente de Spearman ($\rho = 0,78$) puso de manifiesto una elevada concordancia en la ordenación relativa de las densidades espaciales.

Estos resultados parecen indicar que ambas distribuciones comparten determinadas estructuras espaciales generales, aunque sin mantener una relación lineal directa. En consecuencia, los datos apuntan a la presencia de ciertas similitudes espaciales entre ambos grupos, sin que ello constituya evidencia de mecanismos causales o de transmisión directa entre aves y mamíferos.

6.2.4. Evaluación de la capacidad predictiva de las variables geográficas y ecológicas.

Los resultados obtenidos sugieren que determinadas variables geográficas y de contexto ecológico contienen información relevante para la caracterización taxonómica de los registros analizados. El modelo *Random Forest* alcanzó una precisión global del 83,3 % y un F1-macro de 0,73, superando al modelo de Regresión Logística, que obtuvo una precisión del 67,4 % y un F1-macro de 0,56.

El análisis de importancia de variables identificó la longitud (19,82 %) y la latitud (19,73 %) como los predictores de mayor peso, seguidos del tipo de población afectada (`wild_type`, 16,68 %) y la distancia al humedal Ramsar más cercano (13,83 %). Las variables IBA/KBA obtuvieron una contribución inferior al 1 %, lo que parece indicar que su valor descriptivo en el EDA no se traslada a capacidad predictiva en este contexto.

6.2.5. Identificación y documentación de las limitaciones de los datos y modelos.

El desarrollo del trabajo permitió identificar diversas limitaciones asociadas tanto a los datos disponibles como a los modelos construidos. Entre ellas destacan el fuerte desbalance existente entre clases taxonómicas, la representación reducida de mamíferos respecto al conjunto global de registros y la ausencia de variables de naturaleza ambiental o climática que podrían resultar explicativas.

Asimismo, los resultados obtenidos ponen de manifiesto las limitaciones inherentes a los estudios basados en datos observacionales y agregados espacialmente: las relaciones identificadas permiten describir patrones y asociaciones, pero no establecer relaciones causales directas. La identificación explícita de estas limitaciones permite acotar el alcance de las conclusiones obtenidas y orienta posibles líneas de mejora futuras.

6.2.6. Evaluación del rendimiento del modelo global en el contexto español.

El modelo Random Forest entrenado con datos globales se aplicó directamente sobre el subconjunto español (que había sido excluido expresamente del entrenamiento) como evaluación externa en sentido estricto. El modelo alcanzó una precisión del 93,1 % y un F1-macro de 0,92, valores superiores a los obtenidos en la evaluación global (83,3 % y 0,73 respectivamente).

Este resultado parece indicar que los patrones aprendidos por el modelo mantienen su utilidad cuando se trasladan a un contexto geográfico más específico. Desde el punto de vista de la minería de datos, los resultados obtenidos sobre España refuerzan la robustez del enfoque adoptado y apuntan a que las variables geográficas incorporadas durante el proceso de integración forman parte de los factores que contribuyen a la capacidad de generalización observada en el modelo.

6.3. Líneas futuras.

Los resultados obtenidos y las limitaciones identificadas durante el desarrollo del trabajo permiten plantear diversas líneas de continuación.

En primer lugar, resultaría de interés incorporar variables climáticas, ambientales y de movilidad avar que permitan complementar la información utilizada en este estudio. Entre ellas podrían

considerarse indicadores como la temperatura media, máxima o mínima registrada en el momento de detección de cada brote, la humedad relativa, la precipitación acumulada, la velocidad del viento, parámetros asociados a la calidad del aire o estimaciones de los flujos migratorios y desplazamientos de aves entre regiones. La inclusión de este tipo de variables podría mejorar la capacidad explicativa de los modelos y proporcionar una representación más completa de los factores asociados a la aparición de brotes.

En segundo lugar, podría reformularse el problema de aprendizaje abordado. En lugar de predecir el orden taxonómico asociado a cada registro, futuras investigaciones podrían centrarse en estimar directamente indicadores relacionados con el riesgo de transmisión interespecie. Entre ellos podrían considerarse la probabilidad de aparición de brotes en determinadas regiones, el riesgo asociado a especies hospedadoras concretas o la identificación de patrones que favorezcan la transmisión entre aves silvestres y explotaciones avícolas. De este modo, el objetivo del modelo se aproximaría a preguntas de mayor interés epidemiológico.

Finalmente, sería especialmente relevante realizar validaciones temporales prospectivas, entrenando los modelos sobre periodos históricos y evaluando posteriormente su comportamiento sobre datos futuros. Este enfoque permitiría analizar de forma más rigurosa la capacidad predictiva real de los modelos desarrollados.

El trabajo desarrollado constituye una base sólida sobre la que continuar investigando esta problemática mediante conjuntos de datos más amplios, variables adicionales y técnicas de modelado más avanzadas.

Referencias bibliográficas

- [1] S. J. Lycett, F. Duchatel y P. Digard, «A brief history of bird flu,» *Frontiers in Ecology and Evolution*, 2018, Accedido: 2026-06-17. DOI: [10.3389/fevo.2018.00131](https://doi.org/10.3389/fevo.2018.00131). [En línea]. Disponible en: <https://www.frontiersin.org/journals/ecology-and-evolution/articles/10.3389/fevo.2018.00131/full>.
- [2] X. Zhang, Y. Li, H. Chen y J. Wang, «Emergence and transmission dynamics of avian influenza A(H5N1) in 2026,» *Nature Communications*, 2026, Accedido: 2026-06-17. DOI: [10.1038/s41467-026-69344-w](https://doi.org/10.1038/s41467-026-69344-w). [En línea]. Disponible en: <https://www.nature.com/articles/s41467-026-69344-w>.
- [3] Avicultura.mx. «Hemaglutinina y neuraminidasa: principales antígenos de los virus de influenza.» Accedido: 2026-06-17. (2019), [En línea]. Disponible en: <https://www.avicultura.mx/articulos/hemaglutinina-y-neuraminidasa-principales-antigenos-de-los-virus-de-influenza>.
- [4] W. H. O. (WHO). «Avian A(H5N1) Virus.» Accedido: 2026-06-17. (2025), [En línea]. Disponible en: <https://www.who.int/teams/global-influenza-programme/avian-influenza/avian-a-h5n1-virus>.
- [5] C. on the Conservation of Migratory Species of Wild Animals (CMS). «COP15 Doc.26.3.1 – Flyways.» Accedido: 2026-06-17. (2025), [En línea]. Disponible en: https://www.cms.int/sites/default/files/document/2025-11/cms_cop15_doc.26.3.1_flyways_e.pdf.
- [6] Food y A. O. of the United Nations (FAO). «The Global Early Warning System.» Accedido: 2026-06-17. (2026), [En línea]. Disponible en: <https://www.fao.org/one-health/highlights/the-global-early-warning-system/en>.
- [7] P. y. A. (Ministerio de Agricultura. «Influenza Aviar.» Accedido: 2026-06-17. (2025), [En línea]. Disponible en: https://www.mapa.gob.es/es/ganaderia/temas/sanidad-animal-higiene-ganadera/sanidad-animal/enfermedades/influenza-aviar/influenza_aviar.
- [8] E. C. for Disease Prevention y C. (ECDC). «Avian Influenza Overview December 2023 – March 2024.» Accedido: 2026-06-17. (2024), [En línea]. Disponible en: <https://www.ecdc.europa.eu/en/publications-data/avian-influenza-overview-december-2023-march-2024>.

- [9] P. A. H. O. (PAHO). «Epidemiological Update: Avian Influenza A(H5N1) in the Americas Region – 11 March 2026.» Accedido: 2026-06-17. (2026), [En línea]. Disponible en: <https://www.paho.org/en/documents/epidemiological-update-avian-influenza-ah5n1-americas-region-11-march-2026>.
- [10] E. P. on Animal Health y W. (AHAW), «Scientific Opinion on Avian Influenza: Assessment of the 2025 Situation,» *EFSA Journal*, 2025, Accedido: 2026-06-17. DOI: [10.2903/j.efsa.2025.9761](https://doi.org/10.2903/j.efsa.2025.9761). [En línea]. Disponible en: <https://efsa.onlinelibrary.wiley.com/doi/10.2903/j.efsa.2025.9761>.
- [11] C. for Disease Control y P. (CDC). «Highly Pathogenic Avian Influenza A (H5N1): Interim Recommendations for Prevention, Monitoring, and Public Health Investigations.» Accedido: 2026-06-17. (2024), [En línea]. Disponible en: <https://www.cdc.gov/bird-flu/prevention/hpai-interim-recommendations.html>.
- [12] Avinews. «EU Updates Guidelines to Respond to Avian Influenza Threat.» Accedido: 2026-06-17. (2026), [En línea]. Disponible en: <https://avinews.com/en/eu-updates-guidelines-to-respond-to-avian-influenza-threat/>.
- [13] Food y A. O. of the United Nations (FAO). «Global AIV with Zoonotic Potential.» Accedido: 2026-06-17. (2026), [En línea]. Disponible en: <https://www.fao.org/animal-health/situation-updates/global-aiv-with-zoonotic-potential/en>.
- [14] E. E. A. (EEA). «Wetlands.» Accedido: 2026-06-17. (2026), [En línea]. Disponible en: <https://biodiversity.europa.eu/europes-biodiversity/ecosystems/wetlands>.
- [15] Food y A. O. of the United Nations (FAO). «Avian Influenza: Key Facts.» Accedido: 2026-06-17. (2023), [En línea]. Disponible en: <https://openknowledge.fao.org/items/18aa912a-2005-407f-86a2-b2e09e99a8a6>.
- [16] E. Commission. «Avian Influenza.» Accedido: 2026-06-17. (2026), [En línea]. Disponible en: https://food.ec.europa.eu/animals/animal-diseases/diseases-and-control-measures/avian-influenza_en.
- [17] Excélsior. «Gripe aviar podría ser 100 veces peor que el COVID-19, advierten científicos.» Accedido: 2026-06-17. (2024), [En línea]. Disponible en: <https://www.excelsior.com.mx/global/gripe-aviar-podria-ser-100-veces-peor-que-el-covid-19-advierten-cientificos/1644730>.
- [18] U. S. D. of Agriculture (USDA) – APHIS. «HPAI Detections in Wild Birds.» Accedido: 2026-06-17. (2026), [En línea]. Disponible en: <https://www.aphis.usda.gov/livestock-poultry-disease/avian/avian-influenza/hpai-detections/wild-birds?page=1>.

- [19] W. H. O. (WHO). «Influenza A(H5N1): Preguntas y Respuestas.» Accedido: 2026-06-17. (2024), [En línea]. Disponible en: <https://www.who.int/es/news-room/questions-and-answers/item/influenza-h5n1>.
- [20] C. N. de Epidemiología (CNE) – Instituto de Salud Carlos III. «Gripe humana por nuevo subtipo.» Accedido: 2026-06-17. (2026), [En línea]. Disponible en: <https://cne.isciii.es/servicios/enfermedades-transmisibles/enfermedades-a-z/gripe-humana-nuevo-subtipo>.
- [21] FAO. «Influenza aviar: Enfoques y desafíos en las Américas.» Publicación regional de la oficina de la FAO para América Latina y el Caribe, Organización de las Naciones Unidas para la Alimentación y la Agricultura. (2024), [En línea]. Disponible en: <https://www.fao.org/americas/publications/enfoques/influenza-aviar/> (Acceso: 20-04-2026).
- [22] Y. Zhang, H. Li, X. Chen y J. Wang, «Deep learning-based spatiotemporal forecasting of avian influenza outbreaks using integrated environmental and migratory bird data,» *Computers and Electronics in Agriculture*, vol. 219, p. 108 123, 2024, Accedido: 12 abr. 2026. DOI: [10.1016/j.compag.2024.108123](https://www.sciencedirect.com/science/article/pii/S0045790624002982). [En línea]. Disponible en: <https://www.sciencedirect.com/science/article/pii/S0045790624002982>.
- [23] D. E. Swayne, «Global Control of H5 Highly Pathogenic Avian Influenza, 2012–2014,» 2017, Published in Avian Diseases. [En línea]. Disponible en: <https://pmc.ncbi.nlm.nih.gov/articles/PMC5359749/> (Acceso: 20-04-2026).
- [24] A. M. e. a. Sébastien Lambert Billy Bauzile, «A systematic review of mechanistic models used to study avian influenza virus transmission and control,» *Springer Nature*, 2023, Accedido: 2026-06-17. DOI: [10.1186/s13567-023-01219-0](https://link.springer.com/article/10.1186/s13567-023-01219-0). [En línea]. Disponible en: <https://link.springer.com/article/10.1186/s13567-023-01219-0>.
- [25] C. de Datos. «Forecasting con Deep Learning.» Accedido: 12 abr. 2026. (2020), [En línea]. Disponible en: <https://cienciadedatos.net/documentos/py54-forecasting-con-deep-learning>.
- [26] L. F. e. a. Jean Artois Timothée Vergne, «TSpatial risk modelling of highly pathogenic avian influenza in France: Fattening duck farm activity matters,» *PLOS ONE*, 2024, Accedido: 2026-06-17. DOI: [10.1371/journal.pone.0316248](https://doi.org/10.1371/journal.pone.0316248). [En línea]. Disponible en: <https://journals.plos.org/plosone/article/figures?id=10.1371/journal.pone.0316248>.
- [27] MappingGIS. «Los formatos GIS vectoriales más populares.» Accedido: 12 abr. 2026. (2013), [En línea]. Disponible en: <https://mappinggis.com/2013/11/los-formatos-gis-vectoriales-mas-populares/>.

- [28] Hispanopedia. «Shapefile.» Accedido: 12 abr. 2026. (2023), [En línea]. Disponible en: <https://es.hispanopedia.com/wiki/Shapefile>.
- [29] A. Rousier y F. Ntsama, «Historical Data on Animal Disease Outbreaks: The Contribution Made by the OIE Archives,» *Bulletin de l'OIE (Panorama)*, n.º 1, 2019. DOI: [10.20506/bull.2019.1.2913](https://doi.org/10.20506/bull.2019.1.2913). [En línea]. Disponible en: <https://doi.org/10.20506/bull.2019.1.2913>.

clearpage

Anexo A.

Anexo: Fuentes de consulta no citadas

Este apartado recoge recursos web y publicaciones de prensa que sirvieron de apoyo para la contextualización de este trabajo.

- ABC Avícola, *Sitio web corporativo*. [En línea]. Disponible en: abcavicola.com. [Accedido: 12 abr. 2026].
- 20 Minutos, *Mapa de zonas de riesgo por gripe aviar en España*. [En línea]. Disponible en: 20minutos.es/nacional/mapa-zonas-riesgo. [Accedido: 12 abr. 2026].
- Agència Catalana de Seguretat Alimentària (ACSA), *Influenza aviar*. [En línea]. Disponible en: acsa.gencat.cat/influenza-aviar. [Accedido: 12 abr. 2026].
- Eliko Fundazioa, *Hegazti gripea*. [En línea]. Disponible en: eliko.eus/hegazti-gripea. [Accedido: 12 abr. 2026].
- El País, *Gripe aviar H5N1 en México: qué es, cómo se transmite y el riesgo de epidemia*, 5 abr. 2025. [En línea]. Disponible en: elpais.com/mexico/gripe-aviar-h5n1. [Accedido: 12 abr. 2026].
- La Sexta, *Claves de la gripe aviar: zonas en riesgo y contagio en humanos*, 13 nov. 2025. [En línea]. Disponible en: lasexta.com/nacional/claves-gripe-aviar. [Accedido: 12 abr. 2026].
- Andalucía Informa – elDiario.es, *La gripe aviar enciende las alarmas: prohibición de cría al aire libre*. [En línea]. Disponible en: eldiario.es/andalucia/gripe-aviar. [Accedido: 12 abr. 2026].
- El Correo, *Gripe aviar en España: contagios y casos detectados*, 13 nov. 2025. [En línea]. Disponible en: elcorreo.com/economia/gripe-aviar. [Accedido: 12 abr. 2026].
- Tudela Hoy, *Siete municipios de la Ribera de Navarra en alerta frente a la gripe aviar*, 11 nov. 2025. [En línea]. Disponible en: tudelahoy.com/ribera/alerta-navarra. [Accedido: 12 abr. 2026].

Anexo B.

Anexo: Código, errores y parches realizado sobre los datos

Información: En el apartado 4.2.2 de verificación, se listan una serie de fases. Estas están identificadas por numeración romana; en todo este Anexo, cuando se vea numeración romana, se está haciendo referencia a dichas fases.

B.1. Código ejecutado sobre las fuentes.

I. Lectura de datos.

Para la lectura de fichero Excel y su adecuación a dataframe:

```
df = pd.read_excel('../data/brotes1.xlsx')
```

Para ficheros DBF:

```
df = pd.DataFrame(DBF('../data/RiquezaEspecies.dbf'))
```

Para los otros dos ficheros fue necesario añadir parámetros:

```
df_dbf_2 = pd.DataFrame(  
    DBF('../data/features_centroid_publishedPoint.dbf',  
    load=True,  
    encoding='latin-1',  
    char_decode_errors='ignore')  
)
```

```
df_dbf_3 = pd.DataFrame(  
    DBF('../data/sites.dbf',  
    load=True,  
    parserclass=SafeFieldParser,  
    encoding='latin-1')  
)
```

Sin estos parámetros se producían errores como los mostrados en B.2.

II. Conteo de datos.

```
len(df)
```

III. Exposición de 5 líneas de cabecera.

```
df.head(5)
```

IV. Exposición de 5 líneas finales.

```
df.tail(5)
```

V. Detección de tipología de campos.

```
print(df.dtypes)
```

VI. Detección y soluciones a problemas con la tipología.

Proponer cambios de tipo cuando sea apropiado.

VII. Detección de campos vacíos o nulos.

```
print(df.isna().sum())
```

VIII. Resultados porcentuales de campos vacíos o nulos.

```
print(" CAMPO: ")
print("Total de registro erroneos/ vacios :",df[_campo_].isna().sum())
porcentaje = (df[_campo_].isna().sum() / len(df)) * 100
print(f"Representacion porcentual es: {porcentaje:.2f}%")
```

B.2. Errores obtenidos en las fuentes.

FICHERO: features__centroid__publishedPoint.dbf.

Error al ejecutar:

```
df_dbf_1 = pd.DataFrame(DBF('../data/features__centroid__publishedPoint.dbf'))
```

```
-- ERROR --
```

```
UnicodeDecodeError: 'ascii' codec can't decode byte 0xfa ...
```

FICHERO: sites.dbf.

Error al ejecutar:

```
df_dbf_1 = pd.DataFrame(DBF('../data/sites.dbf'))
```

```
-- ERROR --
```

```
UnicodeDecodeError: 'ascii' codec can't decode byte 0xc3 ...
```

B.3. Datos obtenidos en las fuentes.

En este apartado se recoge, para cada fuente de datos, la tipología de campos detectada (fase v) y el resumen de campos vacíos o nulos (fase viii).

B.3.1. Fuentes: brotes1.xlsx

(v) Detección de tipología de campos.

Tabla 12. Fuentes: brotes1.xlsx. Tipología de campos

Campo	Definición	Tipo detectado
Id	Identificador único del registro de brote.	int64
sero_sub_genotype_eng	Serotipo o subtipo/genotipo del virus detectado.	str
disease_eng	Nombre de la enfermedad.	str
iso_code	Código ISO.	str
country	País.	str
region	Región geográfica.	str
reason_for_notification	Motivo de notificación.	str
IN_FUR	Indicador de notificación.	str
Reporting_date	Fecha de notificación.	datetime64[us]
Epi_unit	Unidad epidemiológica.	str
Longitude	Longitud.	float64
Latitude	Latitud.	float64
Location_name	Nombre de localización.	str
level1_area_id	Identificador administrativo.	float64
level1_unique_code	Código único.	str
level1_name	Nombre administrativo.	str
wild_type	Tipo de población.	str
Species	Especie.	str
Ave_mm	Clasificación general.	str
Orden	Orden taxonómico.	str
Unnamed: 20	Campo vacío.	float64
susceptible	Individuos susceptibles.	float64

Campo	Definición	Tipo detectado
cases	Casos detectados.	float64

(viii) Resultados porcentuales de campos vacíos o nulos.

Tabla 13. Fuentes: brotes1.xlsx. Registros erróneos o vacíos

Campo	NaN detectado
sero_sub_genotype_eng	293 (0.55 %)
region	3 (0.01 %)
level1_area_id	26433 (49.48 %)
susceptible	30724 (57.51 %)

B.3.2. Fuentes: RiquezaEspecies.dbf

(v) Detección de tipología de campos.

Tabla 14. Descripción de campos de RiquezaEspecies.dbf

Campo	Tipo	Definición
OBJECTID	Numérico	Identificador único.
COD10X10	Texto	Código UTM 10×10 km.
RIQUEZAESP	Numérico	Riqueza específica.

(viii) Resultados porcentuales de campos vacíos o nulos.

- N/a. No se encontraron campos vacíos o nulos.

B.3.3. Fuentes: features_centroid_publishedPoint.dbf

(v) Detección de tipología de campos.

Tabla 15. Descripción de campos de features_centroid_publishedPoint.dbf

Campo	Tipo	Definición
v_idris	Numérico	Identificador interno.
ramsarid	Numérico	Código Ramsar.
officialna	Texto	Nombre oficial.
iso3	Texto	Código ISO.

Campo	Tipo	Definición
country_en	Texto	País.
area_off	Numérico	Superficie oficial.

(viii) Resultados porcentuales de campos vacíos o nulos.

Tabla 16. Registros erróneos o vacíos en features_centroid_publishedPoint.dbf

Campo	NaN detectado
area_off	2 (0.08 %)

B.3.4. Fuentes: sites.dbf

(v) Detección de tipología de campos.

Tabla 17. Descripción de campos de sites.dbf

Campo	Tipo	Definición
SitRecID	Numérico	Identificador único.
Region	Texto	Región biogeográfica.
Country	Texto	País.
ISO3	Texto	Código ISO.
NatName	Texto	Nombre local.
IntName	Texto	Nombre internacional.
SitLat	Numérico	Latitud.
SitLong	Numérico	Longitud.
IbaStatus	Texto	Estado IBA.
KbaStatus	Texto	Estado KBA.
KbaClass	Texto	Clasificación KBA.
AzeStatus	Texto	Estado AZE.
Source	Texto	Fuente.
DelTxt	Texto	Información adicional.
SitSource	Texto	Procedencia.
LastUpdate	Numérico	Última actualización.
SitAreaKm2	Numérico	Superficie total.
RepAreaKm2	Numérico	Superficie representada.

(viii) Resultados porcentuales de campos vacíos o nulos.

Tabla 18. Registros erróneos o vacíos en sites.dbf

Campo	NaN detectado
SitAreaKm2	1 (0.01 %)
RepAreaKm2	506 (3.61 %)

Anexo C.

Anexo: Relación de Fuentes después de revisión propuesta.

Tras la revisión realizada desde el INIA-CSIC, se aportaron una serie de 5 ficheros. De ellos, solo 3 son los que serán utilizados para la construcción del *dataset*.

C.1. Fichero 1

Aporta las siguientes variables:

Tabla 19. Variables contenidas en esta fuente de datos de brotes

Variable	Tipo	Contenido
country	str	País donde ocurrió el brote
region	str	Región geográfica (Europa, Asia, América...)
Reporting_date	datetime	Fecha de notificación del brote
Longitude	float	Coordenada X del brote
Latitude	float	Coordenada Y del brote
wild_type	str	Ave silvestre o doméstica
Species	str	Especie concreta afectada
Ave_mm	str	Ave o mamífero
Orden	str	Orden taxonómico del animal afectado (véase Tabla 20)

Tabla 20. Distribución de registros por orden taxonómico en el dataset original

Orden	Registros
Galliformes	26801
Anseriformes	11125
Charadriiformes	5329
Accipitriformes	1978
Gruiformes	1889

Orden	Registros
Artiodactyla	1027
Carnivora	941
Suliformes	898
Passeriformes	855
Pelecaniformes	817
Falconiformes	654
Strigiformes	321
Ciconiiformes	190
Columbiformes	112
Cathartiformes	94
Podicipediformes	92
Procellariiformes	81
Sphenisciformes	62
Psittaciformes	53
Phoenicopteriformes	25
Rodentia	15
Gaviiformes	11
Total	53370

C.2. Fichero 2

Aporta las siguientes variables:

Tabla 21. Variables contenidas en esta fuente de datos (IBAs y KBAs)

Variable	Tipo	Contenido
SitRecID	int	Identificador único del área
Region	str	Región geográfica del área
Country	str	País donde está el área
ISO3	str	Código ISO del país
NatName	str	Nombre oficial en idioma local
IntName	str	Nombre en inglés
SitLat	float	Latitud del área
SitLong	float	Longitud del área

Variable	Tipo	Contenido
IbaStatus	str	Estado de clasificación IBA (véase Tabla 22)
KbaStatus	str	Estado de clasificación KBA (véase Tabla 22)
KbaClass	str	Tipo de KBA (véase Tabla 22)
SitSource	str	Fuente del dato
LastUpdate	str	Fecha de última actualización
SitAreaKm2	float	Superficie del área en km ²
RepAreaKm2	float	Superficie representada en km ²
geometry	geometry	Polígono o punto del área

Tabla 22. Valores únicos de las variables categóricas IBA/KBA

Variable	Valor	Registros
IbaStatus	confirmed	9914
IbaStatus	NaN (sin asignación IBA)	43456
KbaStatus	confirmed	10222
KbaStatus	NaN (sin asignación KBA)	43148
KbaClass	Global	5431
KbaClass	Regional	3718
KbaClass	Global/Regional TBD	1073
KbaClass	NaN (sin clasificación)	43148

C.3. Fichero 3

Aporta las siguientes variables:

Tabla 23. Variables contenidas en esta fuente de datos (Humedales Ramsar)

Variable	Tipo	Contenido
v_idris	int	Identificador interno de la base de datos
ramsarid	int	Identificador oficial Ramsar del humedal
officialna	str	Nombre oficial del humedal
iso3	str	Código ISO del país
country_en	str	País en inglés

Variable	Tipo	Contenido
area_off	float	Superficie oficial del humedal en hectáreas
geometry	geometry	Geometría del humedal (puntos)

C.4. Variables del *dataset* enriquecido

Tabla 24. Variables del dataset enriquecido. Descripción detallada

Variable	Tipo	Descripción
country	Texto	País donde ocurrió el brote
region	Texto	Región geográfica del brote
Reporting_date	Fecha	Fecha de notificación del brote
Longitude	Numérico	Coordenada X del brote
Latitude	Numérico	Coordenada Y del brote
wild_type	Texto	Condición de la población afectada
Species	Texto	Especie o familia taxonómica afectada
Ave_mm	Texto	Clasificación general del hospedador
Orden	Texto	Orden taxonómico de la especie afectada
geometry	Geometría	Geometría espacial del brote
SitRecID	Numérico	Identificador del área IBA/KBA asociada
IbaStatus	Texto	Estado de clasificación del área como IBA
KbaStatus	Texto	Estado de clasificación del área como KBA
KbaClass	Texto	Tipo de clasificación KBA
SitAreaKm2	Numérico	Superficie del área IBA/KBA en km ²
dist Ramsar_km	Numérico	Distancia al humedal Ramsar más cercano en km

Anexo D.

Anexo: Licencia y condiciones de acceso a las fuentes de datos.

Los datos empleados en este trabajo fueron facilitados en el marco de la colaboración establecida con el Centro de Investigación en Sanidad Animal del INIA-CSIC, en el contexto del desarrollo de este Trabajo Fin de Grado. Proceden de tres fuentes externas con condiciones de uso diferenciadas, que se detallan a continuación.

Los datos de humedales Ramsar están disponibles bajo licencia Creative Commons Atribución 4.0 Internacional (CC BY 4.0) y han sido obtenidos del Ramsar Sites Information Service (RSIS): *Data obtained from <https://rsis.ramsar.org>. Licensed under Creative Commons Attribution 4.0 International (CC BY 4.0).*

Los datos de áreas de importancia para la biodiversidad (IBA/KBA) fueron obtenidos de BirdLife International Data Zone para uso académico. De acuerdo con las condiciones de uso establecidas por BirdLife International, dichos datos no se distribuyen en este repositorio. Los usuarios interesados pueden solicitarlos directamente a través de: <https://datazone.birdlife.org/contact-us/request-our-data>

Los datos de brotes de Influenza Aviar Altamente Patógena proceden del sistema WOA-H-WAHIS. De acuerdo con las condiciones de uso de la Organización Mundial de Sanidad Animal (WOAH), estos datos son propiedad de dicho organismo y no pueden redistribuirse como datos propios. Los usuarios interesados pueden consultarlos directamente en: <https://wahis.woah.org/#/dashboards/qd-dashboard>